

Plan de proyecto del Trabajo Final
Carrera de Especialización en Inteligencia
Artificial

Síntesis de voz con acento rioplatense basada en inteligencia artificial


Autor: Ing. Ojeda Juan Cruz



Introducción

- Proyecto de síntesis de voz con acento rioplatense basado en IA
- Motivación: La mayoría de las soluciones TTS están en inglés o español neutro
- Objetivo principal: Crear una voz sintética en tiempo real integrándola a un asistente conversacional
- Foco del desarrollo:
 - No sobre el avatar 2D/3D ni sincronización labial
 - MVP funcional con calidad de voz adecuada y baja latencia

Interesados



Propósito

- Brindar una experiencia de interacción virtual inmersiva
- Implementar síntesis de voz con acento rioplatense
- Enriquecer la autenticidad y cercanía de la VTuber basada en IA



Alcance



Incluye

- Asistente con TTS rioplatense
- Feedback de usuarios



Tecnología

- Entrenamiento de modelo
- Integración en backend



Exclusiones


- Avatar / lipsync
- Generación de texto

Product Backlog



Épica 1 - Recolección y preparación de corpus rioplatense

- Recopilar grabaciones de hablantes rioplatenses para asegurar autenticidad
- Limpiar, recortar y etiquetar los audios para entrenar el modelo



Épica 3 - Integración con IA conversacional

- Enlazar el chatbot con el TTS para respuestas audibles con acento rioplatense
- Optimizar latencia y calidad para lograr una interacción fluida

Criterios de aceptación de HU



HU1

- Mínimo 5 horas de grabaciones con hablantes locales
- Audio sin ruidos excesivos y frecuencia adecuada
- Registro del origen y validez de cada grabación



HU2

- Las grabaciones están limpias y recortadas
- Cada clip tiene metadatos estandarizados
- Se documenta el proceso de normalización para asegurar reproducibilidad



HU5

- El TTS convierte automáticamente las respuestas del chatbot en audio
- La latencia es menor a 2 s en el 80 % de los casos
- Sin errores frecuentes de conexión o sincronización



HU6

- Latencia < 1,5 s en pruebas internas
- Mean opinion score $\geq 3,5$ en al menos 70% de las pruebas
- El usuario puede ajustar velocidad y entonación

Fases de Crisp-DM





Diagrama de Gantt



Gestión de riesgos

Riesgo	S	O	RPN	S*	O*	RPN*
Demoras en la recolección del corpus	9	4	36	6	3	18
Calidad insuficiente del audio recolectado	8	5	40	6	2	12
Problemas de compatibilidad con librerías	6	6	36	4	3	12
Modelo con voz poco natural o latencia alta	10	3	30	-	-	-
No se obtiene feedback externo	7	4	28	-	-	-

Mitigación para riesgos con $RPN \geq 35$



Sprint Retrospective

Hacer más de

- Validaciones objetivas como MOS
- Automatización del preprocesamiento

Continuar haciendo

- Control de versiones
- Limpieza de datos por lotes

Hacer menos de

- Pruebas sobre corpus pequeño
- Cambios de arquitectura frecuentes

Comenzar a hacer

- Ajuste de latencia en entorno real
- Métricas perceptuales de calidad

Dejar de hacer

- Evaluación subjetiva sin respaldo cuantitativo
- Cambios sin registrar en el repositorio



Sprint Retrospective



Gracias

