

Análisis de datos - Trabajo práctico integrador.

1. Introducción y motivación

Para este trabajo final deberán realizar el análisis completo para un set de datos y la idea es que trabajen en grupo.

1.1 Datasets disponibles

En la siguiente tabla tienen los datasets propuestos y algunas preguntas orientadoras. Se espera que los alumnos indaguen en las posibilidades de análisis y visualización según el dataset elegido.

Dataset	Preguntas
AirBnB Buenos Aires	¿Cuál es la relación entre el precio de las propiedades y su tipo de alojamiento? ¿Cómo varía la disponibilidad de las propiedades según el número de camas y habitaciones? ¿Existen patrones de precios según la ubicación, por ejemplo, en barrios específicos? ¿Cómo influye la política de cancelación en la calificación de las propiedades? ¿Qué características (número de camas, tipo de propiedad, etc.) están más correlacionadas con la puntuación de los huéspedes? ¿Cómo varía la distribución de precios según el tipo de propiedad y el número de reseñas recibidas?
Crímenes reportados en Chicago (período a elección)	¿Cómo varía la distribución de los crímenes a lo largo de las horas del día, los días de la semana y los meses del año? ¿Se observan anomalías y/o patrones estacionales? ¿Hay diferencias significativas entre el número de crímenes en distintos distritos o comunas? ¿Están las fuerzas policiales bien distribuidas en relación a las características de cada zona? (ej: la mayor cantidad de actividad policial/arrestos se registra en las zonas críticas) ¿Cómo variaron los crímenes en la ciudad después de algún cambio o evento social importante? (ej: Covid-19, protestas, etc.)
Uso de taxis Yellow Cab en USA en el año 2020	¿Cuáles son los patrones de demanda a lo largo del tiempo? ¿Cómo varía la distancia de los viajes según el tipo de servicio? ¿Cuáles son las zonas con mayor actividad de pick-ups y drop-offs? ¿Cómo varían las tarifas según la distancia y el tipo de servicio? ¿Se pueden detectar patrones de fraude o comportamiento anómalo en los datos de viajes? (ejemplo viajes con distancias extremadamente cortas pero tarifas altas)
Uso de High-Volume For-Hire Services (HVFS) en USA en el año 2020	¿Existen diferencias en el número de viajes entre distintos proveedores (Uber, Lyft, etc.)? ¿Cómo varía el número de pasajeros según la hora del día y el tipo de servicio? ¿Hay una relación entre la tarifa y el tiempo de espera del pasajero? ¿Cuáles son los recorridos más rentables en términos de tarifa por milla?

	¿Se pueden identificar patrones espaciales en los viajes? (Ejemplo: viajes dentro de Manhattan vs. viajes a los aeropuertos) ¿Existen diferencias en la tarifa o duración de los viajes según el día de la semana?
Recorridos en Ecobicis en el año 2020	¿Hay diferencias en la duración de los viajes entre hombres y mujeres? ¿Existen patrones temporales en la cantidad de viajes (horas pico, días de la semana, meses)? ¿Qué estaciones tienen mayor flujo de entradas y salidas? ¿Cómo se distribuyen espacialmente los viajes? ¿Se pueden agrupar por zonas según la demanda? ¿La dirección de los viajes sigue alguna tendencia (por ejemplo, más viajes hacia el centro en la mañana y hacia los barrios en la tarde)?
Precios Claros - Base SEPA Elegir alguna de las cadenas grandes de supermercado (Carrefour, Disco, etc.)	¿Cuáles son los productos que más cambian de precio según el día de la semana? ¿Existe un patrón de precios por región? (ejemplo: regiones o grupos de provincias del país con precios muy elevados) ¿Las marcas propias de los supermercados tienen precios más bajos que las marcas líderes? ¿Los precios de los productos esenciales (ejemplo: leche, pan, arroz) varían dependiendo del día de la semana? ¿Cómo influye el tipo de comercio (hipermercado, autoservicio, etc.) en los precios de los productos?
Datos meteorológicos de Argentina	¿Cómo varía la temperatura a lo largo de las estaciones del año? ¿En qué meses se observan los valores más extremos de temperatura, humedad, viento y precipitación? ¿Las tendencias y patrones observados varían entre estaciones meteorológicas? ¿Cómo se compara el último año con la media de los últimos 30 años? ¿Las condiciones actuales y el pronóstico están dentro de lo esperado para esta época del año según los datos históricos?

1.2 Definición de grupos y elección de datasets

La conformación de grupos y elección de dataset debe respetar los siguiente ítems:

- Los grupos deben ser de dos personas. Excepcionalmente, se puede armar un grupo de tres personas.
- Un mismo dataset no puede ser elegido por más de dos grupos.
- Dada la complejidad de los datasets, los grupos de tres personas únicamente podrán seleccionar un dataset de taxis (Yellow Cab o HVFHS).

Completar esta [planilla](#) con los datos del grupo de trabajo y el dataset elegido antes de la clase 2: 13/3/2025.

2. Consignas

El análisis debe abordar los siguientes aspectos:

- Exploración y comprensión de los datos:
 - Cargar el dataset proporcionado y realizar un análisis exploratorio de los datos.
 - Describir las características principales del dataset, incluyendo el número de observaciones, número de variables y tipos de datos.
 - Identificar patrones generales, distribuciones y cualquier anomalía inicial en los datos.
 - Visualizar las variables más importantes para entender sus relaciones y distribuciones.
- Aplicación de técnicas de visualización:
 - Utilizar técnicas de visualización adecuadas para ilustrar las principales características del dataset.
 - Asegurarse de que las visualizaciones sean claras, concisas y efectivas para comunicar la información.
 - Interpretar los resultados obtenidos a partir de las visualizaciones.
- Limpieza del dataset:
 - Identificar y tratar los valores faltantes en el dataset.
 - Detectar y manejar los outliers utilizando técnicas estadísticas o visuales apropiadas.
 - Realizar una limpieza general del dataset, eliminando o corrigiendo datos inconsistentes o irrelevantes.
- Transformación de variables y selección de features:
 - Aplicar técnicas de conversión de variables donde sea necesario.
 - Aplicar técnicas de escalamiento de ser necesario.
 - Realizar una selección de variables basándose en su relevancia y significancia.
 - Justificar la elección de las variables seleccionadas.
- Reducción de la dimensionalidad:
 - Aplicar técnicas de reducción de la dimensionalidad.
 - Comparar el dataset original con el dataset reducido, evaluando las ventajas y desventajas de la reducción.
 - Evaluar cómo la reducción de la dimensionalidad afecta la interpretación y el rendimiento de futuros modelos predictivos.

Deberá enviarse a través del campus el link al repositorio GitHub con la notebook correctamente documentada y organizada, y el archivo de la presentación. La fecha límite es el **15/04/2025** (es decir, dos días antes de la exposición).

3. Evaluación

- El TP se defenderá de forma oral la penúltima clase (**17/04/2025**). La presentación se realizará con diapositivas. De manera opcional, se puede complementar con una demo de la notebook o código desarrollado, siempre y cuando se respeten los tiempos programados.
- Cada grupo tendrá asignado un total de 20 minutos (15' para la exposición y 5' para devolución de las docentes).
- Agenda (tentativa) para el día de la exposición:
 - Exposición grupo 1-3 (60')
 - Break (10')
 - Exposición grupo 4-5 (40')
 - Break (10')
 - Exposición grupo 6-7 (40')
 - Cierre (20')
- Es importante que todos los miembros del grupo expongan de igual manera en términos de tiempo. Es altamente recomendable que, durante la presentación, todos los miembros del grupo tengan la cámara prendida.
- La nota final de la materia será en base al desempeño individual (es importante que se note que el alumno trabajó y comprende en profundidad lo hecho por el grupo) y grupal de este trabajo. También se considerará la participación en clase durante toda la cursada.
Se evaluará:
 - Entendimiento del dominio del dataset
 - La medida en la que el análisis responde a la pregunta planteada
 - El planteo de supuestos y limitaciones
 - Calidad de la presentación
 - Presentación oral individual
 - Visualización de datos
 - Una buena comprensión de los temas vistos en la materia:
 - Limpieza de datos
 - Conversión de variables
 - Manejo de valores faltantes
 - Selección de features
 - Manejo de datos atípicos (outliers)
 - Reducción de dimensionalidad (si aplica) o justificación para no usarla (en caso que no aplique)