

Síntesis de voz con acento rioplatense basada en inteligencia artificial

Ing. Juan Cruz Ojeda

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Jorge Ceferino Valdez (FIUBA)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Rosario, julio de 2025

Resumen

La presente memoria tiene por objeto exponer el desarrollo de un sistema de síntesis de voz con acento rioplatense, concebido como componente vocal de una VTuber basada en inteligencia artificial. El trabajo, de carácter personal, aplica conocimientos avanzados de aprendizaje profundo, procesamiento de señales de audio, fonética rioplatense y ajuste fino de modelos neuronales de texto a voz.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción a la síntesis de voz	1
1.2. Motivación	2
1.3. Estado del arte	2
1.3.1. Síntesis de voz: evolución y estado actual	2
1.3.2. Limitaciones de los modelos existentes en español	3
1.3.3. El acento rioplatense y su ausencia en TTS actuales	3
1.3.4. Visión general de la arquitectura	3
1.3.5. Caso práctico: VTubers basados en inteligencia artificial	4
1.4. Objetivos y alcance	5
1.4.1. Objetivos	5
1.4.2. Alcance	5
2. Introducción específica	7
2.1. Modelos de síntesis utilizados	7
2.2. Fine-tuning para acento local	8
2.3. Tratamiento del corpus	9
2.3.1. Recolección y organización	9
2.3.2. Preprocesamiento de audio	9
2.3.3. Etiquetado y metadatos	9
2.4. Herramientas y entorno técnico	10
2.4.1. Plataforma de desarrollo	10
2.4.2. Bibliotecas de aprendizaje profundo y TTS	10
2.4.3. Infraestructura computacional	10
2.4.4. Organización y trazabilidad del trabajo	10
2.5. Consideraciones lingüísticas del acento rioplatense	11
2.5.1. Rasgos fonéticos distintivos	11
3. Diseño e Implementación	13
Bibliografía	15

Índice de figuras

2.1. Esquema simplificado del <i>pipeline</i> TTS	8
---	---

Índice de tablas

2.1. Comparación de modelos TTS	7
2.2. Tabla de metadatos del corpus	9
2.3. Características del acento rioplatense	11

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se introduce el contexto general del trabajo y se presenta la motivación que dio origen al mismo. A continuación, se expone el estado del arte en materia de síntesis de voz, con especial énfasis en las particularidades del acento rioplatense. Finalmente, se detallan los objetivos definidos y el alcance del proyecto.

1.1. Introducción a la síntesis de voz

La síntesis de voz es un campo de investigación y desarrollo que ha experimentado un crecimiento acelerado en los últimos años [1], impulsado por los avances en inteligencia artificial, el aumento de la capacidad computacional y la disponibilidad de grandes volúmenes de datos. Su aplicación se ha vuelto cada vez más común en interfaces conversacionales, asistentes virtuales, videojuegos, narradores automáticos y sistemas de accesibilidad, entre otros. En este contexto, los modelos modernos de text a voz (*text to speech*, TTS) [2] basados en aprendizaje profundo (*deep learning*) [3] han reemplazado a los métodos tradicionales concatenativos o articulatorios, alcanzando niveles de naturalidad y expresividad que permiten generar locuciones casi indistinguibles de una voz humana real.

A pesar de estos avances, la mayoría de las soluciones de síntesis de voz disponibles están entrenadas para producir habla en inglés u otros idiomas dominantes, con variantes neutras o estandarizadas. Dentro del ámbito hispanohablante, predominan los sistemas basados en el español castellano o en variantes latinoamericanas neutras, diseñadas para maximizar la comprensión en contextos generales. Sin embargo, estos enfoques suelen desestimar las particularidades fonéticas, prosódicas y culturales de los acentos regionales. Esto representa una limitación importante en aplicaciones que buscan generar cercanía, identidad o pertenencia con audiencias específicas.

El acento rioplatense [4], característico del español hablado en Argentina y Uruguay, presenta una serie de rasgos distintivos tanto a nivel fonológico como entonativo. El uso del voseo, la entonación ascendente en ciertas estructuras interrogativas, la pronunciación fricativa de las letras “ll” e “y”, y el ritmo particular del habla son algunos de los elementos que contribuyen a su singularidad. Sin embargo, este acento ha sido escasamente explorado en sistemas de síntesis de voz, lo que deja un vacío en cuanto a herramientas tecnológicas que representen adecuadamente esta variante del español.

En la siguiente sección se presenta la motivación específica que dio origen al trabajo, seguida de un análisis del estado del arte y una definición clara de los objetivos planteados.

1.2. Motivación

En los últimos años, las tecnologías de inteligencia artificial aplicadas al lenguaje han generado un impacto significativo en la forma en que las personas interactúan con los sistemas digitales. La posibilidad de establecer diálogos con asistentes virtuales, personajes animados o agentes conversacionales ha dejado de ser una novedad para convertirse en una herramienta cotidiana en diversas áreas como la educación, el entretenimiento, el soporte técnico y la accesibilidad.

En este escenario, la calidad de la síntesis de voz juega un papel fundamental. Una voz artificial natural, expresiva y adecuada al contexto puede transformar por completo la experiencia del usuario. No obstante, a pesar de los avances logrados en este campo, se observa una marcada escasez de modelos que representen adecuadamente la diversidad lingüística y cultural de los hablantes. La mayoría de los sistemas existentes están entrenados en variantes neutras del español o directamente en inglés, sin contemplar los matices particulares de acentos regionales como el rioplatense.

La motivación principal que dio origen a este trabajo fue la necesidad de contar con una herramienta capaz de generar voz sintética con entonación, timbre y ritmo característicos del acento rioplatense. Sin embargo, hasta el momento, ha sido poco explorado en el ámbito de la síntesis de voz. Esta carencia representa una limitación tanto en términos técnicos como culturales, ya que impide ofrecer experiencias de interacción más cercanas, auténticas y representativas para una amplia comunidad de hablantes.

Además de la dimensión lingüística, se identificó una oportunidad para desarrollar una solución técnica accesible y adaptable, centrada en la representación del habla rioplatense mediante modelos entrenados con datos locales. Esta iniciativa busca no solo cubrir una necesidad tecnológica insatisfecha, sino también habilitar aplicaciones concretas en entornos de entretenimiento digital, especialmente en el desarrollo de VTubers [5] basados en inteligencia artificial que interactúan en tiempo real con audiencias a través de plataformas como Twitch [6].

1.3. Estado del arte

La síntesis de voz es un campo de investigación y desarrollo que ha evolucionado considerablemente en las últimas décadas, especialmente a partir del surgimiento y avance del aprendizaje profundo. El desarrollo actual de modelos de síntesis de voz permite generar audios extremadamente naturales, indistinguibles en muchos casos de voces humanas reales. No obstante, existen limitaciones importantes que justifican la creación de sistemas específicos para diferentes variantes regionales, entre ellas el español rioplatense.

1.3.1. Síntesis de voz: evolución y estado actual

Históricamente, los primeros enfoques de síntesis de voz eran concatenativos, basados en la concatenación de segmentos de audio previamente grabados. Una

tecnología representativa de este método es el sistema Vocaloid [7], conocido popularmente por personajes como Hatsune Miku, que aunque no se clasifica estrictamente como un TTS convencional, genera voz artificial mediante la combinación de fragmentos pregrabados. A estos métodos les sucedieron sistemas paramétricos, que generaban voz mediante reglas acústicas y estadísticas. Sin embargo, la revolución más significativa llegó con la introducción del aprendizaje profundo, particularmente con modelos como Tacotron 2 [8] y FastSpeech 2 [9]. Estos modelos permitieron la generación directa de espectrogramas acústicos (representaciones visuales de frecuencias y energía del sonido) a partir del texto, lo que logró voces más naturales, con expresividad emocional y entonación precisa. Complementariamente, modelos de conversión de espectrogramas en audio conocidos como *vocoder* (codificador-decodificador de voz) neuronales, como HiFi-GAN [10] o WaveGlow [11], produjeron audio con calidad casi indistinguible de una voz humana.

1.3.2. Limitaciones de los modelos existentes en español

Aunque la tecnología actual permite producir síntesis de voz de gran calidad, la mayoría de los desarrollos se concentran en idiomas predominantes como el inglés, o en variantes neutras del español que faciliten la comprensión global. *Frameworks open-source* como Mozilla TTS [12], ESPnet [13] o Coqui TTS [14] disponen de modelos entrenados principalmente en español peninsular o latinoamericano neutro. Este enfoque limita la representación adecuada de las variedades regionales específicas, lo que reduce la capacidad de estos modelos para generar voz auténtica en contextos culturales particulares.

1.3.3. El acento rioplatense y su ausencia en TTS actuales

El acento rioplatense presenta particularidades fonéticas y prosódicas únicas, como el voseo, el sheísmo rehilado, y patrones entonativos específicos que no son adecuadamente representados por los modelos existentes. Hasta el momento, no se encuentran disponibles públicamente modelos de síntesis de voz entrenados específicamente con corpus rioplatense. Esta carencia subraya una clara brecha tecnológica y cultural, lo que destaca la necesidad de iniciativas que permitan el desarrollo de sistemas de síntesis de voz específicamente adaptados a este acento regional.

1.3.4. Visión general de la arquitectura

Desde un punto de vista conceptual, la generación de voz sintética adaptada al acento rioplatense se organiza en una secuencia de etapas bien definidas que permiten transformar texto escrito en audio, asegurando naturalidad y expresividad.

En líneas generales, el sistema incluye un módulo de preprocesamiento textual, donde se normaliza y adapta el texto de entrada. Luego, una red neuronal especializada genera una representación acústica intermedia, conocida como espectrograma, que contiene información detallada sobre pronunciación, ritmo y entonación. Finalmente, un *vocoder* neuronal convierte esta representación en una señal de audio, logrando una voz sintética que reproduce las particularidades del español rioplatense.

Esta arquitectura modular permite trabajar de manera independiente sobre cada componente y adaptar el sistema a las necesidades del dialecto objetivo. Los detalles sobre los modelos empleados, su funcionamiento y evaluación comparativa se desarrollan en la sección 2.1.

1.3.5. Caso práctico: VTubers basados en inteligencia artificial

Un caso destacado de aplicación práctica de los TTS en entretenimiento digital es el del desarrollador conocido como Vedal [15], quien creó el personaje Neuro-sama [16]. Neuro-sama es una VTuber completamente automatizada que utiliza inteligencia artificial para interactuar en tiempo real con la audiencia a través de Twitch. El sistema desarrollado por Vedal implementa múltiples componentes integrados, desde generación automática de respuestas hasta interacción directa con el chat del canal.

Una característica clave de Neuro-sama es su voz sintética, conocida popularmente como *Cute Robot*, que genera diálogos en inglés con un tono distintivo y atractivo para la audiencia. Este sistema TTS procesa en tiempo real los mensajes del chat, otorga prioridad a las donaciones y mensajes destacados y crea así una experiencia interactiva y dinámica. El éxito alcanzado por Neuro-sama destaca el potencial de los sistemas TTS personalizados y adaptados culturalmente, subrayando la oportunidad para desarrollar soluciones similares orientadas al español rioplatense.

El fenómeno de Neuro-sama no solo puso de manifiesto la madurez alcanzada por las tecnologías TTS y de lenguaje natural, sino que también evidenció el valor diferencial que pueden aportar los matices de la voz sintética. Lejos de aspirar a una voz puramente neutra o realista, el diseño de *Cute Robot* prioriza una identidad sonora propia, estilizada y reconocible. Esto subraya la importancia de la voz no solo como canal de comunicación, sino como elemento central de construcción de personaje y de vínculo emocional con el público.

En este contexto, el éxito de Neuro-sama representa una referencia concreta para proyectos similares en otras lenguas o regiones. Desarrollar una versión equivalente adaptada al acento rioplatense, como se propone en el presente trabajo, implicaría no solo entrenar modelos de síntesis con el acento y prosodia local, sino también considerar el estilo conversacional propio del público regional, sus expresiones idiomáticas, su humor y su sensibilidad cultural. Tal adaptación no busca simplemente “traducir” un sistema ya existente, sino crear una experiencia original y culturalmente relevante, que combine innovación tecnológica con identidad lingüística.

Además de su impacto técnico, el caso de Neuro-sama generó un amplio debate en torno al rol de las personalidades artificiales en comunidades virtuales. La audiencia no solo acepta, sino que muchas veces humaniza y proyecta emociones hacia estos personajes, lo que construye una relación similar a la que se tiene con streamers humanos. Esta idea cobra especial relevancia al considerar el modo en que estas tecnologías son recibidas y reinterpretadas por sus audiencias. Esta dinámica refuerza la importancia de una voz sintética que no sea genérica, sino que refleje matices, estilo e identidad, alineados con las expectativas del público. Por ello, el desarrollo de voces con acento rioplatense no solo apunta a una mejora técnica, sino también a una mayor autenticidad y representación cultural dentro de estas nuevas formas de interacción digital.

1.4. Objetivos y alcance

Esta sección tiene por finalidad describir claramente los objetivos generales y específicos establecidos para el presente proyecto, así como delimitar el alcance técnico y metodológico del mismo.

1.4.1. Objetivos

El objetivo general del presente trabajo consistió en diseñar e implementar un sistema de síntesis de voz específicamente adaptado al acento rioplatense, que permita generar audios sintéticos con entonaciones naturales y características propias de esta variante regional del español. Los objetivos específicos definidos fueron:

- Recolectar y procesar un corpus de grabaciones representativas del acento rioplatense para entrenamiento del modelo.
- Seleccionar y configurar una arquitectura adecuada de síntesis de voz basada en aprendizaje profundo, asegurando calidad y naturalidad.
- Desarrollar un modelo TTS funcional que genere voces sintéticas con timbre y prosodia propias del acento rioplatense.
- Evaluar la calidad perceptual de la voz generada mediante pruebas subjetivas y objetivas.

1.4.2. Alcance

El alcance del proyecto comprendió el desarrollo e implementación del motor de síntesis de voz rioplatense basado en modelos de aprendizaje profundo, incluyendo recolección y procesamiento de datos acústicos, entrenamiento y validación del modelo TTS. El alcance no incluyó desarrollo avanzado de interfaces gráficas, diseño de personajes 3D, sincronización labial, plataformas comerciales para streaming, ni la integración automatizada con módulos conversacionales o generación automática de respuestas, limitándose exclusivamente a la generación auditiva del habla sintética a partir de textos ingresados manualmente.

Capítulo 2

Introducción específica

En este capítulo se presentan las técnicas y herramientas utilizadas para la síntesis de voz, **detallando** los modelos considerados, el proceso de *fine-tuning* (ajuste fino) [17] para acento local, el tratamiento aplicado al corpus, las herramientas tecnológicas empleadas y las particularidades lingüísticas del español rioplatense.

2.1. Modelos de síntesis utilizados

En esta sección se presentan brevemente los modelos de síntesis de voz considerados para realizar pruebas preliminares, orientadas al *fine-tuning* con el objetivo de reproducir el acento rioplatense.

Uno de los modelos analizados es Tacotron 2, conocido por generar espectrogramas acústicos naturales mediante una arquitectura autorregresiva basada en redes recurrentes. Otro modelo considerado fue FastSpeech 2, no autorregresivo, que ofrece velocidad de inferencia y estabilidad, características favorables para aplicaciones en tiempo real. Además, se evaluaron modelos basados en *Transformer* (transformador) aplicados a síntesis de voz como Transformer-TTS [18], que destacan por su capacidad para manejar contextos largos y dependencias contextuales profundas.

La tabla 2.1 compara estos modelos mediante métricas numéricas específicas: la calidad auditiva evaluada con la puntuación media de opinión (*Mean Opinion Score*, MOS) [19] y la velocidad de inferencia mediante el factor de tiempo real (*Real Time Factor*, RTF) [20], facilitando así la elección del modelo más apropiado para la adaptación al acento local.

TABLA 2.1. Comparación numérica entre modelos TTS considerados para pruebas preliminares según calidad auditiva (MOS) y velocidad de inferencia (RTF)

Modelo	MOS	RTF
Tacotron 2	4.53	0.132
FastSpeech 2	4.41	0.015
Transformer-TTS	4.39	0.019

Finalmente, la figura 2.1 ilustra el esquema general del *pipeline* (tubería) TTS típico, que incluye entrada de texto, preprocesamiento, generación del espectrograma acústico mediante redes neuronales profundas y conversión final con *vocoders* neuronales.



FIGURA 2.1. Esquema simplificado del *pipeline* TTS empleado en los modelos analizados.

2.2. Fine-tuning para acento local

Para adaptar los modelos previamente seleccionados al español rioplatense, se aplicó una estrategia de aprendizaje por transferencia (*transfer learning*), específicamente mediante *fine-tuning*. Esta técnica consiste en tomar un modelo preentrenado en grandes corpus generales y reentrenarlo parcialmente con corpus representativos del acento objetivo. En este trabajo, el corpus utilizado comprende grabaciones de hablantes nativos del español rioplatense, con diversidad en términos de género, edad y contextos de habla. De este modo, se logró una cobertura adecuada de las particularidades fonéticas y prosódicas propias de este acento.

El proceso de ajuste fino incluyó varias etapas. Inicialmente, se realizó una normalización y limpieza del corpus, con eliminación de ruidos, pausas prolongadas y errores de transcripción. Luego, se etiquetaron y alinearon cuidadosamente los segmentos de audio con su correspondiente texto transcrito. Con el corpus ya preparado, se ajustaron hiperparámetros específicos para controlar el ritmo de aprendizaje del modelo. Con ello se buscó evitar problemas comunes como el sobreajuste (*overfitting*) o la pérdida excesiva de información del entrenamiento original.

Durante el entrenamiento, se monitorearon métricas objetivas como la función de pérdida (*loss function*) y subjetivas mediante evaluaciones perceptuales preliminares. El objetivo fue lograr una representación precisa del acento rioplatense, sin comprometer la calidad auditiva original de los modelos base. Esta estrategia permitió una adaptación eficiente y precisa, con un aprovechamiento óptimo del conocimiento previo adquirido en los modelos preentrenados y una disminución significativa en los recursos computacionales requeridos respecto a entrenar un modelo desde cero.

2.3. Tratamiento del corpus

En esta sección se describe el procedimiento seguido para la preparación, limpieza y anotación de los datos de audio utilizados en el entrenamiento del modelo de síntesis de voz. El tratamiento adecuado del corpus constituye un paso fundamental para garantizar la calidad del sistema y permitir una representación fiel del acento rioplatense.

2.3.1. Recolección y organización

El corpus inicial estuvo compuesto por grabaciones de hablantes nativos del español rioplatense, obtenidas en condiciones acústicas controladas y con consentimiento informado. Se priorizó la diversidad de voces en términos de género, edad y procedencia geográfica dentro del área rioplatense. Cada archivo de audio fue almacenado en formato WAV [21] sin compresión, con una frecuencia de muestreo de 16 kHz, una resolución de 16 bits y acompañado de su correspondiente transcripción textual.

2.3.2. Preprocesamiento de audio

Las grabaciones fueron sometidas a un proceso de limpieza para eliminar ruidos de fondo, silencios prolongados y artefactos no deseados. Se aplicaron filtros de normalización de volumen y recorte automático de bordes silenciosos. Posteriormente, se segmentaron los audios en fragmentos breves. Cada fragmento fue alineado con unidades sintácticas completas, como frases o enunciados simples. Esta organización facilitó el entrenamiento supervisado del modelo.

2.3.3. Etiquetado y metadatos

A cada fragmento de audio se le asociaron metadatos relevantes que permitieron una organización sistemática y una mejor trazabilidad durante el proceso de entrenamiento. En la tabla 2.2 se resumen los campos utilizados en la estructura de anotación.

TABLA 2.2. Estructura de los metadatos asociados a cada fragmento de audio del corpus utilizado para entrenamiento del modelo TTS

Campo	Descripción
Nombre de archivo	Identificador único del fragmento de audio
Transcripción	Texto correspondiente al contenido del audio
Locutor	Alias o código del hablante
Género	Masculino / Femenino / Otro
Edad	Rango etario estimado
Región	Ciudad o provincia de origen del hablante
Duración	Tiempo total del fragmento en segundos

Esta estructuración permitió controlar la diversidad del corpus y facilitar futuras tareas de filtrado o análisis exploratorio. Dado que el proceso completo fue realizado de forma manual y controlada, se garantizó la coherencia entre los audios y sus transcripciones, así como el cumplimiento de los criterios definidos de calidad acústica y representatividad lingüística.

2.4. Herramientas y entorno técnico

En esta sección se describen las herramientas de software, bibliotecas de inteligencia artificial y recursos computacionales considerados durante el desarrollo del trabajo. La correcta selección de estos componentes resulta esencial para garantizar la eficiencia en el entrenamiento de modelos de síntesis de voz y facilitar su experimentación y ajuste.

2.4.1. Plataforma de desarrollo

Para el desarrollo y gestión del código se seleccionó el lenguaje Python [22], ampliamente utilizado en aplicaciones de aprendizaje profundo y procesamiento de señales de audio. El entorno de desarrollo principal utilizado fue Visual Studio Code [23], que permite la integración de cuadernos (*notebooks*) mediante extensiones compatibles con Jupyter [24]. Esta combinación ofreció un entorno flexible y accesible para la ejecución secuencial de bloques de código, visualización de resultados y documentación.

2.4.2. Bibliotecas de aprendizaje profundo y TTS

En relación con el entrenamiento de modelos TTS, se consideraron distintas bibliotecas *open-source* especializadas. Se destaca la biblioteca ESPnet, que ofrece implementaciones modernas y eficientes de modelos como Tacotron 2, FastSpeech 2 y Transformer-TTS. También se evaluó Coqui TTS, una plataforma accesible y activamente mantenida, que facilita el entrenamiento y despliegue de modelos personalizados a partir de configuraciones modulares. Para tareas complementarias se previó el uso de PyTorch [25] como backend principal, junto con NumPy [26], pandas [27] y librosa [28] para análisis, manipulación y visualización de datos acústicos.

2.4.3. Infraestructura computacional

Inicialmente se evaluó la posibilidad de utilizar entornos remotos como Google Colab Pro [29], que ofrecen acceso a unidad de procesamiento gráfico (*graphics processing unit*, GPU) de alto rendimiento. Sin embargo, por simplicidad y conveniencia, se optó por realizar el entrenamiento de los modelos en un entorno local. El equipo utilizado cuenta con un procesador Ryzen 5 2600, 16 GB de memoria RAM a 3200 MHz y una tarjeta gráfica NVIDIA GeForce GTX 1650 con 4 GB de VRAM, configuración que permitió llevar a cabo el trabajo de forma autónoma y controlada.

2.4.4. Organización y trazabilidad del trabajo

Con el fin de mantener un flujo de trabajo ordenado, se estructuraron carpetas jerárquicas para almacenar código, corpus de audio, modelos y resultados de evaluación. Esta organización permitió preservar la trazabilidad de los experimentos y facilitar futuras modificaciones o réplicas del entrenamiento.

La combinación de estas herramientas proporciona un entorno robusto, accesible y alineado con las mejores prácticas actuales en el entrenamiento de modelos de síntesis de voz basados en inteligencia artificial.

2.5. Consideraciones lingüísticas del acento rioplatense

El acento rioplatense presenta una serie de características fonéticas que lo diferencian de otras variedades del español y resultan relevantes en el contexto de la síntesis de voz. Estas particularidades afectan directamente la percepción de naturalidad y autenticidad de las voces generadas. En esta sección se describen los rasgos más destacados que fueron considerados al preparar el corpus y ajustar los modelos utilizados en este trabajo.

2.5.1. Rasgos fonéticos distintivos

Uno de los aspectos más característicos del acento rioplatense es el llamado sheísmo o zheísmo, fenómeno por el cual los sonidos representados por las letras “ll” e “y” se pronuncian de manera similar a una “sh” o “zh” del inglés, en lugar del sonido tradicional de otras variantes del español [30]. Este rasgo tiene un alto valor identitario y resulta clave para lograr una voz sintética que suene naturalmente rioplatense.

También se destaca el uso del voseo, es decir, el empleo del pronombre “vos” en lugar de “tú”, junto con formas verbales específicas. Este rasgo, aunque se relaciona con la gramática, también se manifiesta en la entonación de las formas verbales, y por tanto, influye en la entonación general de la voz generada.

Además, el acento rioplatense presenta una melodía descendente típica en frases declarativas y un ritmo marcado por pausas que tienden a coincidir con los límites sintácticos [31]. El ritmo del habla suele ser silábico, es decir, con pronunciación clara de cada sílaba. Por otro lado, también se observan fenómenos como la omisión de ciertos sonidos en contextos informales, rasgo característico del habla espontánea y popular dentro de la región.

En la tabla 2.3 se resumen los principales rasgos considerados al definir las pautas de pronunciación en los datos utilizados para el entrenamiento.

TABLA 2.3. Características distintivas del acento rioplatense consideradas en el diseño del corpus de entrenamiento

Rasgo	Descripción
Zheísmo/Sheísmo	Pronunciación de “ll” e “y” como “sh” o “zh”
Voseo	Uso de “vos” con formas verbales propias
Entonación descendente	Melodía típica en frases declarativas
Ritmo silábico	Pronunciación clara de cada sílaba
Pausas rítmicas	Pausas que coinciden con los límites de frase
Elisión contextual	Omisión de sonidos en habla informal

Estas particularidades fueron tenidas en cuenta para asegurar que los modelos generen una pronunciación coherente con el acento objetivo, manteniendo la naturalidad y credibilidad esperadas en una voz sintética adaptada al acento rioplatense.

Capítulo 3

Diseño e Implementación

Bibliografía

- [1] Hanaa Barakat, Ozlem Turk y Cagri Demiroglu. «Deep learning-based expressive speech synthesis: a systematic review of approaches, challenges, and resources». En: *EURASIP Journal on Audio, Speech, and Music Processing* 2024.4 (2024), págs. 1-29. DOI: [10.1186/s13636-024-00329-7](https://doi.org/10.1186/s13636-024-00329-7). URL: <https://asmp-urasipjournals.springeropen.com/articles/10.1186/s13636-024-00329-7>.
- [2] Xu Tan et al. «A Survey on Neural Speech Synthesis». En: *ArXiv abs/2106.15561* (2021). URL: <https://arxiv.org/abs/2106.15561>.
- [3] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [4] Wikipedia contributors. *Fonética y fonología del español rioplatense*. 2024. URL: https://es.wikipedia.org/wiki/Fon%C3%A9tica_y_fonolog%C3%ADa_del_espa%C3%B1ol_rioplatense (visitado 17-07-2025).
- [5] Qian Wan y Zhicong Lu. «Investigating VTubing as a Reconstruction of Streamer Self-Presentation: Identity, Performance, and Gender». En: *ArXiv* (2023). URL: <https://arxiv.org/abs/2307.11025>.
- [6] Wikipedia contributors. *Twitch (service)*. 2025. URL: [https://en.wikipedia.org/wiki/Twitch_\(service\)](https://en.wikipedia.org/wiki/Twitch_(service)) (visitado 17-07-2025).
- [7] Hideki Kenmochi e Hiroshi Ohshita. «VOCALOID—Commercial Singing Synthesizer Based on Sample Concatenation». En: *Proceedings of INTERSPEECH*. 2007, págs. 4011-4010.
- [8] Jonathan Shen et al. «Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions». En: *arXiv preprint arXiv:1712.05884* (2018). URL: <https://arxiv.org/abs/1712.05884>.
- [9] Yi Ren et al. «FastSpeech 2: Fast and High-Quality End-to-End Text to Speech». En: *arXiv preprint arXiv:2006.04558* (2020). URL: <https://arxiv.org/abs/2006.04558>.
- [10] Jungil Kong, Jaehyeon Kim y Jaekyoung Bae. «HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis». En: *arXiv preprint arXiv:2010.05646* (2020). URL: <https://arxiv.org/abs/2010.05646>.
- [11] Ryan Prenger, Rafael Valle y Bryan Catanzaro. «WaveGlow: A Flow-based Generative Network for Speech Synthesis». En: *CoRR* (2018). URL: <http://arxiv.org/abs/1811.00002>.
- [12] Mozilla. *Mozilla TTS: Deep learning for Text to Speech synthesis*. <https://github.com/mozilla/TTS>. 2023. (Visitado 10-07-2025).
- [13] Shinji Watanabe et al. «ESPnet: End-to-End Speech Processing Toolkit». En: *Proceedings of Interspeech*. 2018, págs. 2207-2211.
- [14] Coqui AI. *Coqui TTS: a deep learning toolkit for Text-to-Speech*. <https://github.com/coqui-ai/TTS>. 2023. (Visitado 10-07-2025).
- [15] X (Twitter) contributors. *Vedal (@Vedal987)* / X. 2025. URL: <https://x.com/Vedal987> (visitado 17-07-2025).

- [16] Wikipedia contributors. *Neuro-sama*. 2025. URL: <https://en.wikipedia.org/wiki/Neuro-sama> (visitado 17-07-2025).
- [17] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [18] Naihan Li et al. «Close to Human Quality TTS with Transformer». En: *CoRR* (2018). URL: <http://arxiv.org/abs/1809.08895>.
- [19] ITU-T. *Methods for subjective determination of transmission quality*. Inf. téc. P.800. International Telecommunication Union, 1996.
- [20] Heiga Zen, Keiichi Tokuda y Alan W Black. «Statistical parametric speech synthesis». En: *Speech Communication* (2009).
- [21] Microsoft & IBM. *Waveform Audio File Format*. 1991. URL: <https://docs.fileformat.com/audio/wav/> (visitado 18-07-2025).
- [22] Python Software Foundation. *The Python Tutorial*. 2023. URL: <https://docs.python.org/3/tutorial/> (visitado 18-07-2025).
- [23] Microsoft. *Visual Studio Code*. 2019. URL: <https://code.visualstudio.com/> (visitado 18-07-2025).
- [24] Jupyter Team. *Project Jupyter*. 2015. URL: <https://jupyter.org> (visitado 18-07-2025).
- [25] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». En: *Advances in Neural Information Processing Systems* 32 (2019).
- [26] Charles R Harris et al. «Array programming with NumPy». En: *Nature* 585.7825 (2020), págs. 357-362.
- [27] Wes McKinney. «Data structures for statistical computing in Python». En: *Proceedings of the 9th Python in Science Conference* 445 (2010), págs. 51-56.
- [28] Brian McFee et al. «librosa: Audio and music signal analysis in Python». En: *Proceedings of the 14th python in science conference*. Vol. 8. 2015, págs. 18-25.
- [29] Google Research. *Google Colaboratory*. 2017. URL: <https://colab.research.google.com> (visitado 18-07-2025).
- [30] María Beatriz Fontanella de Weinberg. *El español hablado en el Río de la Plata: historia, variación y características actuales*. Universidad Nacional de La Plata, 1992.
- [31] Ellen M. Kaisse. «The prosodic structure of Argentinian Spanish». En: *Hispanic Linguistics* 8.2 (1996), págs. 1-24.