

Síntesis de voz con acento rioplatense basada en inteligencia artificial

Autor

Ing. Juan Cruz Ojeda

Director del trabajo

Esp. Ing. Jorge Valdez

Este plan de trabajo ha sido realizado en el marco de la asignatura Gestión de Proyectos entre el 11 de marzo de 2025 y el 22 de abril de 2025.

Tabla de contenido

1. Breve resumen del trabajo realizado hasta la fecha	2
2. Avance en las tareas	4
3. Cumplimiento de los requerimientos	5
4. Gestión de riesgos	6

IMPORTANTE: No borrar las consignas en cada una de las cuatro secciones de este documento, de forma tal que el jurado tenga claro qué es lo solicitado en cada caso, así como el significado de los símbolos y colores utilizados.

Revisión	Cambios realizados	Fecha
1.0	Creación del documento	18/07/2025

1. Breve resumen del trabajo realizado hasta la fecha

Elabore un detalle del estado del proyecto a la fecha. **Utilicé como mínimo dos páginas completas y como máximo tres páginas.** Explique muy brevemente en qué consiste su Trabajo Final, **aunque esa información esté más detallada en el Plan de Trabajo al cual su Jurado también tiene acceso.** Incluya imágenes y tablas según considere apropiado. **Indique con claridad por qué estima que podrá completar todos los faltantes (o al menos la gran mayoría) antes del inicio del Taller de Trabajo Final.**

El presente Trabajo Final tiene como objetivo desarrollar un sistema de síntesis de voz con acento rioplatense basado en inteligencia artificial, destinado a alimentar la parte vocal de una VTuber automatizada. El enfoque del proyecto parte de una necesidad concreta: la ausencia de motores de síntesis de voz en español rioplatense que puedan generar habla natural, expresiva y culturalmente cercana para audiencias de Argentina y Uruguay.

La solución propuesta consiste en un sistema de síntesis de voz (*Text-to-Speech*, TTS) entrenado específicamente con corpus de habla local, diseñado para generar audios que reproduzcan los rasgos fonéticos, prosódicos y entonativos del español rioplatense. A diferencia de los enfoques tradicionales, este proyecto se estructura según principios de metodologías ágiles, organizando el trabajo en sprints iterativos que permiten entregables parciales funcionales, ajustes sobre la marcha y validaciones tempranas.

A la fecha, se han completado con éxito los sprints 0, 1, 2, 3 y 4, lo que representa una porción significativa del trabajo planificado. Actualmente se encuentra en desarrollo el sprint 5, que corresponde al entrenamiento del modelo principal de síntesis y a la realización de pruebas unitarias del pipeline completo.

Estado actual del proyecto

A continuación, se detallan los principales hitos alcanzados en los sprints ya completados:

Sprint 0: Planificación inicial

Se definió el alcance del proyecto, se elaboró el Product Backlog, se identificaron los stakeholders, los criterios de éxito y los riesgos iniciales. También se diseñó la estrategia de desarrollo basada en CRISP-DM y se estableció una estimación de 600 horas totales.

Sprint 1: Corpus y entorno de trabajo

Se recopiló el corpus de voz con acento rioplatense, incluyendo grabaciones propias y fuentes abiertas, garantizando diversidad de género y edad. Paralelamente, se configuró el entorno técnico para el entrenamiento, incluyendo Python, bibliotecas TTS (Tacotron, FastSpeech), y herramientas como ESPnet y Coqui TTS. El entorno de desarrollo fue validado con éxito en equipo local con GPU.

Sprint 2: Limpieza y etiquetado de datos

Las grabaciones fueron normalizadas, limpiadas de ruidos, recortadas y segmentadas. Cada clip fue etiquetado con metadatos (género, región, duración, etc.), generando una base sólida para el entrenamiento. Se documentó todo el procedimiento para garantizar trazabilidad y reproducibilidad.

Sprint 3: Preprocesamiento y validación del corpus

Se completó el pipeline de preprocesamiento automático, incluyendo segmentación por frases, control de calidad acústica y validación manual de muestras. Se diseñaron scripts reutilizables para convertir los audios en espectrogramas compatibles con los modelos TTS seleccionados.

Sprint 4: Selección de arquitectura y prototipo

Se analizaron tres modelos candidatos: Tacotron 2, FastSpeech 2 y Transformer-TTS. Se eligió FastSpeech 2 por su balance entre calidad (MOS > 4.4) y velocidad de inferencia (RTF < 0.02), ideal para aplicaciones en tiempo real. Se implementó un pipeline funcional capaz de convertir texto simple en espectrogramas acústicos, y se documentaron las decisiones de arquitectura y dependencias utilizadas.

Sprint en desarrollo

Actualmente se desarrolla el Sprint 5, enfocado en el entrenamiento del modelo final y la ejecución de pruebas unitarias. Se ha iniciado el fine-tuning del modelo seleccionado utilizando el corpus rioplatense preparado en los sprints anteriores. Se monitorean métricas como loss, MOS subjetivo interno, consistencia en la entonación y timbre. El entrenamiento avanza sin complicaciones técnicas significativas, gracias al entorno controlado y a la documentación previa.

Evaluación del avance y proyección

El grado de avance actual permite proyectar con confianza la finalización del proyecto antes del inicio del Taller de Trabajo Final B. Esto se debe a:

- El trabajo ya realizado cubre los cimientos más complejos: corpus, arquitectura y preprocesamiento.
- La planificación detallada en historias de usuario con tareas desglosadas por sprint asegura control granular y realista del progreso.
- Se han identificado y mitigado riesgos clave como la calidad del audio y la compatibilidad técnica, reduciendo su RPN a valores aceptables.
- Se cuenta con documentación técnica continua y scripts reproducibles, lo que facilita el escalado, ajustes o validación externa.

En la figura 1 se observa el esquema del pipeline general del sistema TTS




Figura 1: esquema simplificado de entrada de texto, generación de espectrogramas y síntesis final.

En la tabla 1 se muestra el estado de los sprints completados.

Tabla 1. Avance de los sprints

Sprint	Historias asociadas	Estado
0	Planificación inicial	Completo
1	HU1 + DEV3	Completo
2	HU2 + DEV4	Completo
3	HU2 + DEV5	Completo
4	HU3 + DEV6	Completo
5	HU4 + TEST2	En desarrollo

Conclusión

El proyecto avanza de forma sostenida, cumpliendo los objetivos parciales y validando hipótesis técnicas clave. La combinación de un enfoque ágil, documentación rigurosa, herramientas reproducibles y un objetivo claro de MVP centrado en la síntesis vocal garantiza que los próximos sprints (entrenamiento completo, validación, documentación y defensa) puedan desarrollarse dentro del cronograma previsto.

2. Avance en los sprints

a) Indicar a continuación para cada una de las tareas su estado de situación según su criterio, utilizando verde si considera que es satisfactorio, amarillo si considera que es insatisfactorio por sobrecostos y/o demoras, y rojo si lo considera muy insatisfactorio por sobrecostos y/o demoras.

Si a la fecha de completar este informe no está previsto que la tarea haya comenzado entonces deje la celda correspondiente en blanco, sin pintarla con ningún color.

En subcelda inferior izquierda colocar:

- ** si los recursos u horas utilizadas fueron o están siendo muy inferior a lo planificado.
- * si los recursos u horas utilizadas fueron o están siendo inferior a lo planificado.
- \$ si los recursos u horas utilizadas fueron o están siendo de acuerdo a lo planificado.
- \$\$ si los recursos u horas utilizadas fueron o están siendo superiores a lo planificado.
- \$\$\$ si los recursos u horas utilizadas fueron o están siendo muy superior a lo planificado.

En subcelda inferior derecha colocar:

- -- si la tarea se ejecutó o se está ejecutando mucho más rápido de lo previsto
- - si la tarea se ejecutó o se está ejecutando más rápido de lo previsto
- = si la tarea se ejecutó o se está ejecutando en el tiempo previsto.
- + si la tarea se ejecutó o se está ejecutando con demoras.
- ++ si la tarea se ejecutó o se está ejecutando con demoras muy significativas.

IMPORTANTE: Indicar con borde grueso las tareas que forman parte del camino crítico

Sprint 0		Sprint 1		Sprint 2		Sprint 3	
*	-	\$	=	\$	=	\$	=
Sprint 4		Sprint 5		Sprint 6		Sprint 7	
\$\$	=	\$\$	++				
Sprint 8		Sprint 9		Sprint 10		Sprint 11	
Sprint 12		Sprint 13		Sprint 14			

3. Product Backlog

a) Indicar a continuación para cada uno de los requerimientos el estado de situación según su criterio, utilizando verde si considera que ya se ha cumplido, amarillo si considera que aún no se ha cumplido pero se podrá cumplir, y rojo si considera que aún no se ha cumplido y tiene dudas si se podrá cumplir.

Si considera que es necesario modificar los requerimientos respecto a los indicados en la planificación inicial entonces incluya acá los requerimientos actualizados, **marcando en negrita** aquellos que son nuevos o se han modificado.

Épica #1: Recolección y preparación de corpus rioplatense

Épica #2: Diseño y entrenamiento del modelo TTS

Épica #3: Integración con IA conversacional

Épica #4: Validación y pruebas finales

4. Gestión de riesgos

a) Indicar a continuación para cada uno de los riesgos el estado de situación según su criterio, utilizando verde si considera que el riesgo ya no se manifestará o es muy improbable que se manifieste, amarillo si considera que es posible que es improbable que el riesgo se manifieste o si se manifiesta estima que será fácilmente controlado, y rojo si considera que es muy probable que el riesgo se manifieste y que no pueda ser controlado fácilmente.

Si considera que es necesario modificar los riesgos respecto a los presentados en la planificación inicial entonces incluya acá los riesgos actualizados, **marcando en negrita** aquellos que son nuevos o se han modificado, e indicando para ellos los valores de S, O y RPN, junto con su respectiva justificación.

Riesgo #1: Demoras en la recolección del corpus
Riesgo #2: Calidad insuficiente del audio recolectado
Riesgo #3: Problemas de compatibilidad con bibliotecas.
Riesgo #4: Modelo con voz poco natural o latencia alta
Riesgo #5: No se consigue feedback externo