

Síntesis de voz con acento rioplatense basada en inteligencia artificial

Ing. Juan Cruz Ojeda

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Jorge Ceferino Valdez (FIUBA)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Rosario, julio de 2025

Resumen

La presente memoria tiene por objeto exponer el desarrollo de un sistema de síntesis de voz con acento rioplatense, concebido como componente vocal de una VTuber basada en inteligencia artificial. El proyecto, de carácter personal, aplica conocimientos avanzados de aprendizaje profundo, procesamiento de señales de audio, fonética rioplatense y ajuste fino de modelos neuronales TTS (*Text To Speech*, texto a voz).

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción a la síntesis de voz	1
1.2. Motivación	2
1.3. Estado del arte	3
1.3.1. Síntesis de voz: evolución y estado actual	3
1.3.2. Limitaciones de los modelos existentes en español	3
1.3.3. El acento rioplatense y su ausencia en TTS actuales	3
1.3.4. Arquitectura general del sistema propuesto	4
1.3.5. Caso práctico: VTubers basados en inteligencia artificial	4
1.4. Objetivos y alcance	5
1.4.1. Objetivos	5
1.4.2. Alcance	5
Bibliografía	7

Índice de figuras

1.1. Diagrama de arquitectura general del sistema propuesto.	4
--	---

Índice de tablas

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se introduce el contexto general del proyecto y se presenta la motivación que dio origen al mismo. A continuación, se expone el estado del arte en materia de síntesis de voz, con especial énfasis en las particularidades del acento rioplatense. Finalmente, se detallan los objetivos definidos y el alcance del proyecto.

1.1. Introducción a la síntesis de voz

La síntesis de voz es un campo de investigación y desarrollo que ha experimentado un crecimiento acelerado en los últimos años, impulsado por los avances en inteligencia artificial, el aumento de la capacidad computacional y la disponibilidad de grandes volúmenes de datos. Su aplicación se ha vuelto cada vez más común en interfaces conversacionales, asistentes virtuales, videojuegos, narradores automáticos y sistemas de accesibilidad, entre otros. En este contexto, los modelos modernos de TTS basados en aprendizaje profundo han reemplazado a los métodos tradicionales concatenativos o articulatorios, alcanzando niveles de naturalidad y expresividad que permiten generar locuciones casi indistinguibles de una voz humana real.

A pesar de estos avances, la mayoría de las soluciones de síntesis de voz disponibles están entrenadas para producir habla en inglés u otros idiomas dominantes, con variantes neutras o estandarizadas. Dentro del ámbito hispanohablante, predominan los sistemas basados en el español castellano o en variantes latinoamericanas neutras, diseñadas para maximizar la comprensión en contextos generales. Sin embargo, estos enfoques suelen desestimar las particularidades fonéticas, prosódicas y culturales de los acentos regionales. Esto representa una limitación importante en aplicaciones que buscan generar cercanía, identidad o pertenencia con audiencias específicas.

El acento rioplatense, característico del español hablado en Argentina y Uruguay, presenta una serie de rasgos distintivos tanto a nivel fonológico como entonativo. El uso del voseo, la entonación ascendente en ciertas estructuras interrogativas, la pronunciación fricativa de las letras “ll” e “y”, y el ritmo particular del habla son algunos de los elementos que contribuyen a su singularidad. Sin embargo, este acento ha sido escasamente explorado en sistemas de síntesis de voz, lo que deja un vacío en cuanto a herramientas tecnológicas que representen adecuadamente esta variante del español.

Frente a esta situación, se identificó la oportunidad de desarrollar un sistema de síntesis de voz entrenado específicamente para reproducir el acento rioplatense.

El objetivo central fue construir un motor TTS capaz de generar locuciones con características propias de esta variante regional, priorizando la naturalidad, la claridad y la fidelidad fonética. Este sistema se pensó como componente vocal de un asistente conversacional o avatar digital, con especial foco en aplicaciones de entretenimiento, educación o interacción automatizada.

El desarrollo se basó en técnicas de aprendizaje profundo y en la utilización de corpus de habla representativos del español rioplatense. A través de la selección de una arquitectura adecuada, la preparación cuidadosa de los datos y una estrategia iterativa de entrenamiento y evaluación, se buscó construir un prototipo funcional que pudiera generar voz sintética con un timbre, ritmo y entonación afines a los hablantes de la región del Río de la Plata. La introducción de este sistema apunta a cubrir una necesidad específica no atendida por las soluciones comerciales actuales, y al mismo tiempo, representa una contribución concreta a la diversidad lingüística dentro del campo de la inteligencia artificial aplicada al lenguaje.

1.2. Motivación

En los últimos años, las tecnologías de inteligencia artificial aplicadas al lenguaje han generado un impacto significativo en la forma en que las personas interactúan con los sistemas digitales. La posibilidad de establecer diálogos con asistentes virtuales, personajes animados o agentes conversacionales ha dejado de ser una novedad para convertirse en una herramienta cotidiana en diversas áreas como la educación, el entretenimiento, el soporte técnico y la accesibilidad.

En este escenario, la calidad de la síntesis de voz juega un papel fundamental. Una voz artificial natural, expresiva y adecuada al contexto puede transformar por completo la experiencia del usuario. No obstante, a pesar de los avances logrados en este campo, se observa una marcada escasez de modelos que representen adecuadamente la diversidad lingüística y cultural de los hablantes. La mayoría de los sistemas existentes están entrenados en variantes neutras del español o directamente en inglés, sin contemplar los matices particulares de acentos regionales como el rioplatense.

La motivación principal que dio origen a este trabajo fue la necesidad de contar con una herramienta capaz de generar voz sintética con entonación, timbre y ritmo característicos del español rioplatense. Este acento, ampliamente reconocido y utilizado en Argentina y Uruguay, posee rasgos distintivos que lo diferencian de otras variantes del idioma. Sin embargo, hasta el momento, ha sido poco explorado en el ámbito de la síntesis de voz. Esta carencia representa una limitación tanto en términos técnicos como culturales, ya que impide ofrecer experiencias de interacción más cercanas, auténticas y representativas para una amplia comunidad de hablantes.

Además de la dimensión lingüística, se identificó una oportunidad para desarrollar una solución técnica accesible y adaptable, centrada en la representación del habla rioplatense mediante modelos entrenados con datos locales. Esta iniciativa busca no solo cubrir una necesidad tecnológica insatisfecha, sino también habilitar aplicaciones concretas en entornos de entretenimiento digital, especialmente en el desarrollo de VTubers basados en inteligencia artificial que interactúan en tiempo real con audiencias a través de plataformas como Twitch.

1.3. Estado del arte

La síntesis de voz es un campo de investigación y desarrollo que ha evolucionado considerablemente en las últimas décadas, especialmente a partir del surgimiento y avance del aprendizaje profundo. El desarrollo actual de modelos de síntesis de voz permite generar audios extremadamente naturales, indistinguibles en muchos casos de voces humanas reales. No obstante, existen limitaciones importantes que justifican la creación de sistemas específicos para diferentes variantes regionales, entre ellas el español rioplatense.

1.3.1. Síntesis de voz: evolución y estado actual

Históricamente, los primeros enfoques de síntesis de voz eran concatenativos, basados en la concatenación de segmentos de audio previamente grabados. Una tecnología representativa de este método es el sistema Vocaloid [1], conocido popularmente por personajes como Hatsune Miku, que aunque no se clasifica estrictamente como un TTS convencional, genera voz artificial mediante la combinación de fragmentos pregrabados. A estos métodos les sucedieron sistemas paramétricos, que generaban voz mediante reglas acústicas y estadísticas. Sin embargo, la revolución más significativa llegó con la introducción del aprendizaje profundo, particularmente con modelos como Tacotron 2 [2] y FastSpeech 2 [3]. Estos modelos permitieron la generación directa de espectrogramas acústicos (representaciones visuales de frecuencias y energía del sonido) a partir del texto, logrando voces más naturales, con expresividad emocional y entonación precisa. Complementariamente, modelos de conversión de espectrogramas en audio conocidos como vocoders neuronales, como HiFi-GAN [4], produjeron audio con calidad casi indistinguible de una voz humana.

1.3.2. Limitaciones de los modelos existentes en español

Aunque la tecnología actual permite producir síntesis de voz de gran calidad, la mayoría de los desarrollos se concentran en idiomas predominantes como el inglés, o en variantes neutras del español que faciliten la comprensión global. *Frameworks open-source* como Mozilla TTS [5], ESPnet [6] o Coqui TTS [7] disponen de modelos entrenados principalmente en español peninsular o latinoamericano neutro. Este enfoque limita la representación adecuada de las variedades regionales específicas, reduciendo la capacidad de estos modelos para generar voz auténtica en contextos culturales particulares.

1.3.3. El acento rioplatense y su ausencia en TTS actuales

El español rioplatense, hablado principalmente en Argentina y Uruguay, presenta particularidades fonéticas y prosódicas únicas, como el voseo, el yeísmo rehilado, y patrones entonativos específicos que no son adecuadamente representados por los modelos existentes. Hasta el momento, no se encuentran disponibles públicamente modelos de síntesis de voz entrenados específicamente con corpus rioplatense. Esta carencia subraya una clara brecha tecnológica y cultural, destacando la necesidad de iniciativas que permitan el desarrollo de sistemas de síntesis de voz específicamente adaptados a este acento regional.

1.3.4. Arquitectura general del sistema propuesto

El sistema desarrollado aborda esta brecha mediante una arquitectura integrada, que consta de tres componentes principales: un módulo conversacional (chat box), un motor de síntesis de voz rioplatense y la salida auditiva final, como se observa en la figura 1.1.




FIGURA 1.1. Diagrama de arquitectura general del sistema propuesto.

El proceso comienza con un texto generado o introducido en el chat box, el cual se envía al motor de síntesis. Internamente, este motor procesa el texto mediante normalización lingüística y tokenización, para luego generar representaciones intermedias como espectrogramas acústicos utilizando modelos basados en FastSpeech o Tacotron. Estos espectrogramas se convierten en audio con la ayuda de un vocoder neuronal, como HiFi-GAN. Finalmente, el resultado auditivo reproduce una voz sintética que conserva fielmente las características particulares del acento rioplatense.

Esta arquitectura asegura flexibilidad y calidad, adaptándose específicamente a las necesidades del español rioplatense.

1.3.5. Caso práctico: VTubers basados en inteligencia artificial

Un caso destacado de aplicación práctica del TTS en entretenimiento digital es el del desarrollador conocido como Vedal, quien creó el personaje Neuro-sama. Neuro-sama es una VTuber completamente automatizada que utiliza inteligencia artificial para interactuar en tiempo real con la audiencia a través de Twitch. El sistema desarrollado por Vedal implementa múltiples componentes integrados, desde generación automática de respuestas hasta interacción directa con el chat del canal.

Una característica clave de Neuro-sama es su voz sintética, conocida popularmente como *Cute Robot*, que genera diálogos en inglés con un tono distintivo y atractivo para la audiencia. Este sistema TTS procesa mensajes provenientes del chat en tiempo real, priorizando especialmente las donaciones y mensajes destacados, lo que crea una experiencia interactiva y dinámica. El éxito alcanzado por Neuro-sama destaca el potencial de los sistemas TTS personalizados y adaptados culturalmente, subrayando la oportunidad para desarrollar soluciones similares orientadas al español rioplatense.

1.4. Objetivos y alcance

Esta sección tiene por finalidad describir claramente los objetivos generales y específicos establecidos para el presente proyecto, así como delimitar el alcance técnico y metodológico del mismo.

1.4.1. Objetivos

El objetivo general del presente trabajo consistió en diseñar e implementar un sistema de síntesis de voz específicamente adaptado al acento rioplatense, que permita generar audios sintéticos con entonaciones naturales y características propias de esta variante regional del español. Los objetivos específicos definidos fueron:

- Recolectar y procesar un corpus de grabaciones representativas del acento rioplatense para entrenamiento del modelo.
- Seleccionar y configurar una arquitectura adecuada de síntesis de voz basada en aprendizaje profundo, asegurando calidad y naturalidad.
- Desarrollar un modelo TTS funcional que genere voces sintéticas con timbre y prosodia propias del acento rioplatense.
- Evaluar la calidad perceptual de la voz generada mediante pruebas subjetivas y objetivas.

1.4.2. Alcance

El alcance del proyecto comprendió el desarrollo e implementación del motor de síntesis de voz rioplatense basado en modelos de aprendizaje profundo, incluyendo recolección y procesamiento de datos acústicos, entrenamiento y validación del modelo TTS. El alcance no incluyó desarrollo avanzado de interfaces gráficas, diseño de personajes 3D, sincronización labial, plataformas comerciales para streaming, ni la integración automatizada con módulos conversacionales o generación automática de respuestas, limitándose exclusivamente a la generación auditiva del habla sintética a partir de textos ingresados manualmente.

Bibliografía

- [1] Hideki Kenmochi e Hiroshi Ohshita. «VOCALOID—Commercial Singing Synthesizer Based on Sample Concatenation». En: *Proceedings of INTERSPEECH*. 2007, págs. 4011-4010.
- [2] Jonathan Shen et al. «Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions». En: *arXiv preprint arXiv:1712.05884* (2018). URL: <https://arxiv.org/abs/1712.05884>.
- [3] Yi Ren et al. «FastSpeech 2: Fast and High-Quality End-to-End Text to Speech». En: *arXiv preprint arXiv:2006.04558* (2020). URL: <https://arxiv.org/abs/2006.04558>.
- [4] Jungil Kong, Jaehyeon Kim y Jaekyoung Bae. «HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis». En: *arXiv preprint arXiv:2010.05646* (2020). URL: <https://arxiv.org/abs/2010.05646>.
- [5] Mozilla. *Mozilla TTS: Deep learning for Text to Speech synthesis*. <https://github.com/mozilla/TTS>. 2023. (Visitado 10-07-2025).
- [6] Shinji Watanabe et al. «ESPnet: End-to-End Speech Processing Toolkit». En: *Proceedings of Interspeech*. 2018, págs. 2207-2211.
- [7] Coqui AI. *Coqui TTS: a deep learning toolkit for Text-to-Speech*. <https://github.com/coqui-ai/TTS>. 2023. (Visitado 10-07-2025).