

Síntesis de voz con acento rioplatense basada en inteligencia artificial

Ing. Juan Cruz Ojeda

Carrera de Especialización en Inteligencia Artificial

Director: Esp. Ing. Jorge Ceferino Valdez (FIUBA)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Rosario, diciembre de 2025

Resumen

La presente memoria tiene por objeto exponer el desarrollo de un sistema de síntesis de voz con acento rioplatense, concebido como componente vocal de una VTuber basada en inteligencia artificial. El trabajo, de carácter personal, aplica conocimientos avanzados de aprendizaje profundo, procesamiento de señales de audio, fonética rioplatense y ajuste fino de modelos neuronales de texto a voz.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción a la síntesis de voz	1
1.2. Motivación	2
1.3. Estado del arte	2
1.3.1. Síntesis de voz: evolución y estado actual	2
1.3.2. Limitaciones de los modelos existentes en español	3
1.3.3. El acento rioplatense y su ausencia en TTS actuales	3
1.3.4. Visión general de la arquitectura	3
1.3.5. Caso práctico: VTubers basados en inteligencia artificial	4
1.4. Objetivos y alcance	5
1.4.1. Objetivos	5
1.4.2. Alcance	5
2. Introducción específica	7
2.1. Ajuste fino de modelos preentrenados	7
2.2. Modelos de síntesis utilizados	7
2.3. Tratamiento del corpus	8
2.3.1. Recolección y organización	9
2.3.2. Preprocesamiento de audio	9
2.3.3. Etiquetado y metadatos	9
2.4. Herramientas y entorno técnico	10
2.4.1. Plataforma de desarrollo	10
2.4.2. Bibliotecas de aprendizaje profundo y TTS	10
2.4.3. Infraestructura computacional	10
2.4.4. Organización y trazabilidad del trabajo	10
2.5. Consideraciones lingüísticas del acento rioplatense	11
2.5.1. Rasgos fonéticos distintivos	11
3. Diseño e implementación	13
3.1. Arquitectura general del sistema	13
3.1.1. Restricciones prácticas y criterios de diseño	13
3.1.2. Estructura modular y escalabilidad	14
3.1.3. Compatibilidad y reproducibilidad	14
3.2. Recolección y preparación del corpus	15
3.2.1. Elección de fuentes	15
3.2.2. Problemas enfrentados	15
3.2.3. Justificación de decisiones	15
3.2.4. Consideraciones legales y éticas	16
3.3. Modelo TTS seleccionado	16
3.3.1. Paradigma de modelos TTS basados en <i>Transformers</i>	16

3.3.2.	Modelos anteriores: Tacotron 2 y FastSpeech	16
3.3.3.	Arquitectura y funciones del modelo SpeechT5	17
3.3.4.	Justificación de la elección de SpeechT5	17
3.3.5.	Evaluación preliminar para español rioplatense	17
3.4.	Entrenamiento y ajustes	18
3.5.	Integración y validación	18
3.6.	Documentación y reproducibilidad	18
4.	Ensayos y Resultados	19
4.1.	Banco de pruebas	19
4.1.1.	Subsection 1	19
4.2.	Pruebas del modelo TTS	19
4.3.	Pruebas de integración	19
4.4.	Comparación de resultados	19
4.5.	Validación con usuarios	19
4.6.	Caso de uso ejemplar	19
5.	Conclusiones	21
5.1.	Resultados obtenidos	21
5.2.	Trabajo futuro	21
	Bibliografía	23

Índice de figuras

2.1. Esquema simplificado del <i>pipeline</i> TTS	8
3.1. Arquitectura funcional del sistema TTS	14

Índice de tablas

2.1. Comparación de modelos TTS	8
2.2. Tabla de metadatos del corpus	9
2.3. Características del acento rioplatense	11

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se introduce el contexto general del trabajo y se presenta la motivación que dio origen al mismo. A continuación, se expone el estado del arte en materia de síntesis de voz, con especial énfasis en las particularidades del acento rioplatense. Finalmente, se detallan los objetivos definidos y el alcance del proyecto.

1.1. Introducción a la síntesis de voz

La síntesis de voz es un campo de investigación y desarrollo que ha experimentado un crecimiento acelerado en los últimos años [1], impulsado por los avances en inteligencia artificial, el aumento de la capacidad computacional y la disponibilidad de grandes volúmenes de datos. Su aplicación se ha vuelto cada vez más común en interfaces conversacionales, asistentes virtuales, videojuegos, narradores automáticos y sistemas de accesibilidad, entre otros. En este contexto, los modelos modernos de text a voz (*Text To Speech*, TTS) [2] basados en aprendizaje profundo (*deep learning*) [3] han reemplazado a los métodos tradicionales concatenativos o articulatorios, con niveles de naturalidad y expresividad tales que permiten generar locuciones casi indistinguibles de una voz humana real.

A pesar de estos avances, la mayoría de las soluciones de síntesis de voz disponibles están entrenadas para producir habla en inglés u otros idiomas dominantes, con variantes neutras o estandarizadas. Dentro del ámbito hispanohablante, predominan los sistemas basados en el español castellano o en variantes latinoamericanas neutras, diseñadas para maximizar la comprensión en contextos generales. Sin embargo, estos enfoques suelen desestimar las particularidades fonéticas, prosódicas y culturales de los acentos regionales. Esto representa una limitación importante en aplicaciones que buscan generar cercanía, identidad o pertenencia con audiencias específicas.

El acento rioplatense [4], característico del español hablado en Argentina y Uruguay, presenta una serie de rasgos distintivos tanto a nivel fonológico como entonativo. El uso del voseo, la entonación ascendente en ciertas estructuras interrogativas, la pronunciación fricativa de los fonemas tradicionalmente asociados a /ɰ/ y /j/ (realizados en esta variante como /ɜ/, /ʃ/ o /j/) y el ritmo particular del habla son algunos de los elementos que contribuyen a su singularidad. Sin embargo, este acento ha sido escasamente explorado en sistemas de síntesis de voz, lo que deja un vacío en cuanto a herramientas tecnológicas que representen adecuadamente esta variante del español.

1.2. Motivación

En los últimos años, las tecnologías de inteligencia artificial aplicadas al lenguaje han generado un impacto significativo en la forma en que las personas interactúan con los sistemas digitales. La posibilidad de establecer diálogos con asistentes virtuales, personajes animados o agentes conversacionales ha dejado de ser una novedad para convertirse en una herramienta cotidiana en diversas áreas como la educación, el entretenimiento, el soporte técnico y la accesibilidad.

En este escenario, la calidad de la síntesis de voz juega un papel fundamental. Una voz artificial natural, expresiva y adecuada al contexto puede transformar por completo la experiencia del usuario. No obstante, a pesar de los avances logrados en este campo, se observa una marcada escasez de modelos que representen adecuadamente la diversidad lingüística y cultural de los hablantes. La mayoría de los sistemas existentes están entrenados en variantes neutras del español o directamente en inglés, sin contemplar los matices particulares de acentos regionales como el rioplatense.

La motivación principal que dio origen a este trabajo fue la necesidad de contar con una herramienta capaz de generar voz sintética con entonación, timbre y ritmo característicos del acento rioplatense. Sin embargo, hasta el momento, ha sido poco explorado en el ámbito de la síntesis de voz. Esta carencia representa una limitación tanto en términos técnicos como culturales, ya que impide ofrecer experiencias de interacción más cercanas, auténticas y representativas para una amplia comunidad de hablantes.

Además de la dimensión lingüística, se identificó una oportunidad para desarrollar una solución técnica accesible y adaptable, centrada en la representación del habla rioplatense mediante modelos entrenados con datos locales. Esta iniciativa busca no solo cubrir una necesidad tecnológica insatisfecha, sino también habilitar aplicaciones concretas en entornos de entretenimiento digital, especialmente en el desarrollo de VTubers [5] basados en inteligencia artificial que interactúan en tiempo real con audiencias a través de plataformas como Twitch [6].

1.3. Estado del arte

La síntesis de voz es un campo de investigación y desarrollo que ha evolucionado considerablemente en las últimas décadas, especialmente a partir del surgimiento y avance del aprendizaje profundo. El desarrollo actual de modelos de síntesis de voz permite generar audios extremadamente naturales, indistinguibles en muchos casos de voces humanas reales. No obstante, existen limitaciones importantes que justifican la creación de sistemas específicos para diferentes variantes regionales, entre ellas el español rioplatense.

1.3.1. Síntesis de voz: evolución y estado actual

Históricamente, los primeros enfoques de síntesis de voz eran concatenativos, basados en la concatenación de segmentos de audio previamente grabados. Una

tecnología representativa de este método es el sistema Vocaloid [7], conocido popularmente por personajes como Hatsune Miku, que aunque no se clasifica estrictamente como un TTS convencional, genera voz artificial mediante la combinación de fragmentos pregrabados. A estos métodos les sucedieron sistemas paramétricos, que generaban voz mediante reglas acústicas y estadísticas. Sin embargo, la revolución más significativa llegó con la introducción del aprendizaje profundo, particularmente con modelos como Tacotron 2 [8] y FastSpeech 2 [9]. Estos modelos permitieron la generación directa de espectrogramas acústicos (representaciones visuales de frecuencias y energía del sonido) a partir del texto, lo que logró voces más naturales, con expresividad emocional y entonación precisa. Complementariamente, modelos de conversión de espectrogramas en audio conocidos como *vocoder* (codificador-decodificador de voz) neuronales, como HiFi-GAN [10] o WaveGlow [11], produjeron audio con calidad casi indistinguible de una voz humana.

1.3.2. Limitaciones de los modelos existentes en español

Aunque la tecnología actual permite producir síntesis de voz de gran calidad, la mayoría de los desarrollos se concentran en idiomas predominantes como el inglés, o en variantes neutras del español que faciliten la comprensión global. *Frameworks open-source* como Mozilla TTS [12], ESPnet [13] o Coqui TTS [14] disponen de modelos entrenados principalmente en español peninsular o latinoamericano neutro. Este enfoque limita la representación adecuada de las variedades regionales específicas, lo que reduce la capacidad de estos modelos para generar voz auténtica en contextos culturales particulares.

1.3.3. El acento rioplatense y su ausencia en TTS actuales

El acento rioplatense presenta particularidades fonéticas y prosódicas únicas, como el voseo, el *sheísmo* rehilado, y patrones entonativos específicos que no son adecuadamente representados por los modelos existentes. Hasta el momento, no se encuentran disponibles públicamente modelos de síntesis de voz entrenados específicamente con corpus rioplatense. Esta carencia subraya una clara brecha tecnológica y cultural, lo que destaca la necesidad de iniciativas que permitan el desarrollo de sistemas de síntesis de voz específicamente adaptados a este acento regional.

1.3.4. Visión general de la arquitectura

Desde un punto de vista conceptual, la generación de voz sintética adaptada al acento rioplatense se organiza en una secuencia de etapas bien definidas que permiten transformar texto escrito en audio, lo que asegura naturalidad y expresividad.

En líneas generales, el sistema incluye un módulo de preprocesamiento textual, donde se normaliza y adapta el texto de entrada. Luego, una red neuronal especializada genera una representación acústica intermedia, conocida como espectrograma, que contiene información detallada sobre pronunciación, ritmo y entonación. Finalmente, un *vocoder* neuronal convierte esta representación en una señal de audio, lo que logra una voz sintética que reproduce las particularidades del español rioplatense.

Esta arquitectura modular permite trabajar de manera independiente sobre cada componente y adaptar el sistema a las necesidades del dialecto objetivo. Los detalles sobre los modelos empleados, su funcionamiento y evaluación comparativa se desarrollan en la sección 2.2.

1.3.5. Caso práctico: VTubers basados en inteligencia artificial

Un caso destacado de aplicación práctica de los TTS en entretenimiento digital es el del desarrollador conocido como Vedal [15], quien creó el personaje Neuro-sama [16]. Neuro-sama es una VTuber completamente automatizada que utiliza inteligencia artificial para interactuar en tiempo real con la audiencia a través de Twitch. El sistema desarrollado por Vedal implementa múltiples componentes integrados, desde generación automática de respuestas hasta interacción directa con el chat del canal.

Una característica clave de Neuro-sama es su voz sintética, conocida popularmente como *Cute Robot*, que genera diálogos en inglés con un tono distintivo y atractivo para la audiencia. Este sistema TTS procesa en tiempo real los mensajes del chat, otorga prioridad a las donaciones y mensajes destacados y crea así una experiencia interactiva y dinámica. El éxito alcanzado por Neuro-sama destaca el potencial de los sistemas TTS personalizados y adaptados culturalmente, lo que pone de manifiesto la oportunidad para desarrollar soluciones similares orientadas al español rioplatense.

El fenómeno de Neuro-sama no solo puso de manifiesto la madurez alcanzada por las tecnologías TTS y de lenguaje natural, sino que también evidenció el valor diferencial que pueden aportar los matices de la voz sintética. Lejos de aspirar a una voz puramente neutra o realista, el diseño de *Cute Robot* prioriza una identidad sonora propia, estilizada y reconocible. Esto subraya la importancia de la voz no solo como canal de comunicación, sino como elemento central de construcción de personaje y de vínculo emocional con el público.

En este contexto, el éxito de Neuro-sama representa una referencia concreta para proyectos similares en otras lenguas o regiones. Desarrollar una versión equivalente adaptada al acento rioplatense, como se propone en el presente trabajo, implicaría no solo entrenar modelos de síntesis con el acento y prosodia local, sino también considerar el estilo conversacional propio del público regional, sus expresiones idiomáticas, su humor y su sensibilidad cultural. Tal adaptación no busca simplemente traducir un sistema ya existente, sino crear una experiencia original y culturalmente relevante, que combine innovación tecnológica con identidad lingüística.

Además de su impacto técnico, el caso de Neuro-sama generó un amplio debate en torno al rol de las personalidades artificiales en comunidades virtuales. La audiencia no solo acepta, sino que muchas veces humaniza y proyecta emociones hacia estos personajes, lo que construye una relación similar a la que se tiene con streamers humanos. Esta idea cobra especial relevancia al considerar el modo en que estas tecnologías son recibidas y reinterpretadas por sus audiencias. Esta dinámica refuerza la importancia de una voz sintética que no sea genérica, sino que refleje matices, estilo e identidad, alineados con las expectativas del público. Por ello, el desarrollo de voces con acento rioplatense no solo apunta a una mejora técnica, sino también a una mayor autenticidad y representación cultural dentro de estas nuevas formas de interacción digital.

1.4. Objetivos y alcance

Esta sección tiene por finalidad describir claramente los objetivos generales y específicos establecidos para el presente trabajo, así como delimitar el alcance técnico y metodológico del mismo.

1.4.1. Objetivos

El objetivo general del presente trabajo consistió en diseñar e implementar un sistema de síntesis de voz específicamente adaptado al acento rioplatense, que permita generar audios sintéticos con entonaciones naturales y características propias de esta variante regional del español. Los objetivos específicos definidos fueron:

- Recolectar y procesar un corpus de grabaciones representativas del acento rioplatense para entrenamiento del modelo.
- Seleccionar y configurar una arquitectura adecuada de síntesis de voz basada en aprendizaje profundo, lo que asegura la calidad y naturalidad.
- Desarrollar un modelo TTS funcional que genere voces sintéticas con timbre y prosodia propias del acento rioplatense.
- Evaluar la calidad perceptual de la voz generada mediante pruebas subjetivas y objetivas.

1.4.2. Alcance

El alcance del trabajo comprendió el desarrollo e implementación del motor de síntesis de voz rioplatense basado en modelos de aprendizaje profundo, lo que incluye recolección y procesamiento de datos acústicos, entrenamiento y validación del modelo TTS. El alcance no incluyó desarrollo avanzado de interfaces gráficas, diseño de personajes 3D, sincronización labial, plataformas comerciales para transmisión en directo (*streaming*), ni la integración automatizada con módulos conversacionales o generación automática de respuestas, limitándose exclusivamente a la generación auditiva del habla sintética a partir de textos ingresados manualmente.

Capítulo 2

Introducción específica

En este capítulo se presentan las técnicas y herramientas utilizadas para la síntesis de voz, donde se detallan los modelos considerados, el proceso de ajuste fino (*fine-tuning*) [17] para acento local, el tratamiento aplicado al corpus, las herramientas tecnológicas empleadas y las particularidades lingüísticas del español rioplatense.

2.1. Ajuste fino de modelos preentrenados

En tareas de síntesis de voz, es común utilizar el procedimiento conocido como *fine-tuning*, mediante el cual un modelo previamente entrenado es adaptado a un nuevo dominio o acento específico. Esta técnica permite reutilizar redes neuronales que ya han aprendido representaciones generales del habla, lo que reduce el tiempo de entrenamiento y la cantidad de datos necesarios. En el contexto de este trabajo, el *fine-tuning* resulta particularmente útil para adaptar modelos de síntesis entrenados en español general al acento rioplatense.

2.2. Modelos de síntesis utilizados

En esta sección se presentan brevemente los modelos de síntesis de voz considerados para realizar pruebas preliminares, orientadas al *fine-tuning* con el objetivo de reproducir el acento rioplatense.

Uno de los modelos analizados es Tacotron 2, conocido por generar espectrogramas acústicos naturales mediante una arquitectura autorregresiva basada en redes recurrentes. Otro modelo considerado fue FastSpeech 2, no autorregresivo, que ofrece velocidad de inferencia y estabilidad, características favorables para aplicaciones en tiempo real. Además, se evaluaron modelos basados en *Transformer* (transformador) aplicados a síntesis de voz como Transformer-TTS [18], que destacan por su capacidad para manejar contextos largos y dependencias contextuales profundas.

La tabla 2.1 compara estos modelos mediante métricas numéricas específicas: la calidad auditiva evaluada con la puntuación media de opinión (*Mean Opinion Score*, MOS) [19] y la velocidad de inferencia mediante el factor de tiempo real (*Real Time Factor*, RTF) [20], lo que facilita la elección del modelo más apropiado para la adaptación al acento local.

TABLA 2.1. Comparación numérica entre modelos TTS considerados para pruebas preliminares según calidad auditiva (MOS) y velocidad de inferencia (RTF).

Modelo	MOS	RTF
Tacotron 2	4,53	0,132
FastSpeech 2	4,41	0,015
Transformer-TTS	4,39	0,019

Finalmente, la figura 2.1 ilustra el esquema general del *pipeline* (tubería) TTS típico, que incluye entrada de texto, preprocesamiento, generación del espectrograma acústico mediante redes neuronales profundas y conversión final con *vocoders* neuronales.




FIGURA 2.1. Esquema simplificado del *pipeline* TTS empleado en los modelos analizados.

2.3. Tratamiento del corpus

En esta sección se describe el procedimiento seguido para la preparación, limpieza y anotación de los datos de audio utilizados en el entrenamiento del modelo de síntesis de voz. El tratamiento adecuado del corpus constituye un paso fundamental para garantizar la calidad del sistema y permitir una representación fiel del acento rioplatense.

2.3.1. Recolección y organización

El corpus inicial estuvo compuesto por grabaciones de hablantes nativos del español rioplatense, obtenidas en condiciones acústicas controladas y con consentimiento informado. Se priorizó la diversidad de voces en términos de género, edad y procedencia geográfica dentro del área rioplatense. Cada archivo de audio fue almacenado en formato WAV [21] sin compresión, con una frecuencia de muestreo de 16 kHz, una resolución de 16 bits y acompañado de su correspondiente transcripción textual.

2.3.2. Preprocesamiento de audio

Las grabaciones fueron sometidas a un proceso de limpieza para eliminar ruidos de fondo, silencios prolongados y artefactos no deseados. Se aplicaron filtros de normalización de volumen y recorte automático de bordes silenciosos. Posteriormente, se segmentaron los audios en fragmentos breves. Cada fragmento fue alineado con unidades sintácticas completas, como frases o enunciados simples. Esta organización facilitó el entrenamiento supervisado del modelo.

2.3.3. Etiquetado y metadatos

A cada fragmento de audio se le asociaron metadatos relevantes que permitieron una organización sistemática y una mejor trazabilidad durante el proceso de entrenamiento. En la tabla 2.2 se resumen los campos utilizados en la estructura de anotación.

TABLA 2.2. Estructura de los metadatos asociados a cada fragmento de audio del corpus utilizado para entrenamiento del modelo TTS.

Campo	Descripción
Nombre de archivo	Identificador único del fragmento de audio
Transcripción	Texto correspondiente al contenido del audio
Locutor	Alias o código del hablante
Género	Masculino / Femenino / Otro
Edad	Rango etario estimado
Región	Ciudad o provincia de origen del hablante
Duración	Tiempo total del fragmento en segundos

Esta estructuración permitió controlar la diversidad del corpus y facilitar futuras tareas de filtrado o análisis exploratorio. Dado que el proceso completo fue realizado de forma manual y controlada, se garantizó la coherencia entre los audios y sus transcripciones, así como el cumplimiento de los criterios definidos de calidad acústica y representatividad lingüística.

2.4. Herramientas y entorno técnico

En esta sección se describen las herramientas de software, bibliotecas de inteligencia artificial y recursos computacionales considerados durante el desarrollo del trabajo. La correcta selección de estos componentes resulta esencial para garantizar la eficiencia en el entrenamiento de modelos de síntesis de voz y facilitar su experimentación y ajuste.

2.4.1. Plataforma de desarrollo

Para el desarrollo y gestión del código se seleccionó el lenguaje Python [22], ampliamente utilizado en aplicaciones de aprendizaje profundo y procesamiento de señales de audio. El entorno de desarrollo principal utilizado fue Visual Studio Code [23], que permite la integración de cuadernos (*notebooks*) mediante extensiones compatibles con Jupyter [24]. Esta combinación ofreció un entorno flexible y accesible para la ejecución secuencial de bloques de código, visualización de resultados y documentación.

2.4.2. Bibliotecas de aprendizaje profundo y TTS

En relación con el entrenamiento de modelos TTS, se consideraron distintas bibliotecas *open-source* especializadas. Se destaca la biblioteca `ESPnet`, que ofrece implementaciones modernas y eficientes de modelos como Tacotron 2, FastSpeech 2 y Transformer-TTS. También se evaluó `Coqui TTS`, una plataforma accesible y activamente mantenida, que facilita el entrenamiento y despliegue de modelos personalizados a partir de configuraciones modulares. Para tareas complementarias se previó el uso de `PyTorch` [25] como backend principal, junto con `NumPy` [26], `pandas` [27] y `librosa` [28] para análisis, manipulación y visualización de datos acústicos.

2.4.3. Infraestructura computacional

Inicialmente se evaluó la posibilidad de utilizar entornos remotos como Google Colab Pro [29], que ofrecen acceso a unidad de procesamiento gráfico (*graphics processing unit*, GPU) de alto rendimiento. Sin embargo, por simplicidad y conveniencia, se optó por realizar el entrenamiento de los modelos en un entorno local. El equipo utilizado cuenta con un procesador Ryzen 5 2600, 16 GB de memoria RAM a 3200 MHz y una tarjeta gráfica NVIDIA GeForce GTX 1650 con 4 GB de VRAM, configuración que permitió llevar a cabo el trabajo de forma autónoma y controlada.

2.4.4. Organización y trazabilidad del trabajo

Con el fin de mantener un flujo de trabajo ordenado, se estructuraron carpetas jerárquicas para almacenar código, corpus de audio, modelos y resultados de evaluación. Esta organización permitió preservar la trazabilidad de los experimentos y facilitar futuras modificaciones o réplicas del entrenamiento.

La combinación de estas herramientas proporciona un entorno robusto, accesible y alineado con las mejores prácticas actuales en el entrenamiento de modelos de síntesis de voz basados en inteligencia artificial.

2.5. Consideraciones lingüísticas del acento rioplatense

El acento rioplatense presenta una serie de características fonéticas que lo diferencian de otras variedades del español y resultan relevantes en el contexto de la síntesis de voz. Estas particularidades afectan directamente la percepción de naturalidad y autenticidad de las voces generadas. En esta sección se describen los rasgos más destacados que fueron considerados al preparar el corpus y ajustar los modelos utilizados en este trabajo.

2.5.1. Rasgos fonéticos distintivos

Uno de los aspectos más característicos del acento rioplatense es el llamado *sheísmo* o *zheísmo*, fenómeno por el cual los fonemas tradicionalmente asociados a las grafías *ll* e *y* se pronuncian como las fricativas /ʃ/ o /ʒ/ en lugar de las realizaciones más tradicionales en otras variantes del español [30]. Este rasgo tiene un alto valor identitario y resulta clave para lograr una voz sintética que suene naturalmente rioplatense.

También se destaca el uso del voseo, es decir, el empleo del pronombre *vos* (en lugar de *tú*), junto con formas verbales específicas. Este rasgo, aunque se relaciona con la gramática, también se manifiesta en la entonación de las formas verbales y, por tanto, influye en la entonación general de la voz generada.

Además, el acento rioplatense presenta una melodía descendente típica en frases declarativas y un ritmo marcado por pausas que tienden a coincidir con los límites sintácticos [31]. El ritmo del habla suele ser silábico, es decir, con pronunciación clara de cada sílaba. Por otro lado, también se observan fenómenos como la omisión de ciertos sonidos en contextos informales, rasgo característico del habla espontánea y popular dentro de la región.

En la tabla 2.3 se resumen los principales rasgos considerados al definir las pautas de pronunciación en los datos utilizados para el entrenamiento.

TABLA 2.3. Características distintivas del acento rioplatense consideradas en el diseño del corpus de entrenamiento.

Rasgo	Descripción
<i>zheísmo</i> / <i>sheísmo</i>	Pronunciación de <i>ll</i> e <i>y</i> como /ʃ/ o /ʒ/
Voseo	Uso del pronombre <i>vos</i> con formas verbales propias
Entonación descendente	Melodía típica en frases declarativas
Ritmo silábico	Pronunciación clara de cada sílaba
Pausas rítmicas	Pausas que coinciden con los límites de frase
Elisión contextual	Omisión de sonidos en habla informal

Estas particularidades fueron tenidas en cuenta para asegurar que los modelos generen una pronunciación coherente con el acento objetivo y mantengan la naturalidad y credibilidad esperadas en una voz sintética adaptada al acento rioplatense.

Capítulo 3

Diseño e implementación

En este capítulo se presenta el diseño detallado del sistema de síntesis de voz con acento rioplatense, con énfasis en los problemas encontrados durante su desarrollo. Además, se explican los criterios técnicos utilizados y las justificaciones detrás de cada decisión tomada. Por último, se describe la arquitectura general y luego se profundiza en cada etapa del proceso, desde la preparación de los datos hasta la validación del sistema completo.

3.1. Arquitectura general del sistema

Esta sección describe conceptualmente cómo se estructura el sistema propuesto, se presentan sus componentes principales, los criterios que guiaron su diseño y cómo estos componentes se integran para cumplir los requisitos del trabajo.

3.1.1. Restricciones prácticas y criterios de diseño

El diseño general del sistema estuvo fuertemente condicionado por la disponibilidad de recursos computacionales locales, previamente detallada en la subsección 2.4.3. Dado que el trabajo no cuenta con financiamiento externo ni acceso a infraestructura de alto rendimiento, se priorizó el uso de modelos que pudieran ser entrenados y ejecutados de forma autónoma en un entorno limitado, sin requerir inversiones adicionales ni suscripciones a plataformas comerciales.

Este criterio llevó a descartar arquitecturas más complejas o recientes, como los modelos de tipo de difusión (*diffusion*) o generativos autoregresivos pesados, entre ellos VALL-E [32], NaturalSpeech 2 [33] y Voicebox [34], que si bien ofrecen resultados de vanguardia en términos de calidad perceptual, requieren tiempos de entrenamiento prolongados, consumo intensivo de GPU y grandes volúmenes de datos.

En su lugar, se optó por utilizar el modelo SpeechT5 [35] de Microsoft, una arquitectura robusta y versátil que permite realizar síntesis de voz con resultados competitivos, al tiempo que admite el *fine-tuning* sobre corpus específicos y puede ejecutarse en entornos controlados con recursos computacionales moderados. Esta decisión implicó aceptar una calidad de síntesis limitada por las condiciones del entorno, pero suficiente para demostrar la viabilidad del sistema y su adaptabilidad al acento rioplatense.

3.1.2. Estructura modular y escalabilidad

La arquitectura fue diseñada con una estructura modular que permite aislar responsabilidades funcionales, lo que facilita tanto la depuración como futuras modificaciones. Cada etapa del *pipeline* (preprocesamiento, inferencia, vocoder) puede reemplazarse o reentrenarse de manera independiente. Esta decisión favorece la escalabilidad del sistema y habilita la incorporación de nuevas funcionalidades, como conversión de estilo, síntesis emocional o adaptación a otros dialectos, sin necesidad de reentrenar el modelo completo.

3.1.3. Compatibilidad y reproducibilidad

Durante el diseño se priorizó el uso de herramientas *open-source* y formatos estándar, lo que asegura la compatibilidad con diferentes entornos de ejecución. Además, se definieron criterios mínimos de reproducibilidad: el sistema puede instalarse y ejecutarse tanto en un entorno local con GPU de gama media como en plataformas en la nube previamente consideradas, como Google Colab. Este enfoque facilita la replicación del experimento por parte de otros investigadores o desarrolladores, alineándose con buenas prácticas académicas y de software libre.

La figura 3.1 muestra una representación esquemática de la arquitectura funcional del sistema diseñado.




FIGURA 3.1. Arquitectura funcional del sistema de síntesis de voz propuesto. Se representan los módulos principales del procesamiento: entrada de texto, preprocesamiento, modelo SpeechT5 ajustado, generación del espectrograma, vocoder HiFi-GAN y salida final en formato de audio.

3.2. Recolección y preparación del corpus

En esta sección se detallan las acciones realizadas para llevar a cabo la recolección, limpieza y preparación del corpus de voz rioplatense. Si bien en el capítulo anterior se describieron las técnicas empleadas, aquí se abordan los desafíos prácticos encontrados durante el proceso y las decisiones adoptadas para garantizar la calidad y representatividad de los datos utilizados.

3.2.1. Elección de fuentes

Inicialmente se evaluaron diversas alternativas para obtener grabaciones en español rioplatense y se tuvo en cuenta la opción de utilizar podcast o videos disponibles públicamente en plataformas de Internet. Aunque esta opción fue considerada, finalmente se optó por priorizar fuentes que ofrecieran mayor control sobre la calidad del audio y la diversidad del contenido.

Dos fuentes principales conformaron finalmente el corpus utilizado: un conjunto de datos públicos alojados en la plataforma Hugging Face [36], seleccionados específicamente por su calidad acústica, representatividad fonética y grabaciones propias. Para estas últimas, en lugar del tradicional método de grabación en estudio o en casa, se eligió una metodología práctica basada en grabaciones realizadas durante llamadas de voz a través de la aplicación Discord [37]. Con la utilización de un bot específico para esta plataforma, se obtuvo automáticamente un archivo de audio individual para cada participante de la llamada. Este método no solo facilitó la recolección de datos, sino que permitió captar conversaciones reales y espontáneas y con ello se logró una mayor naturalidad y representatividad del corpus.

3.2.2. Problemas enfrentados

Durante el procesamiento inicial del corpus se identificaron varios desafíos técnicos. En primer lugar, la segmentación de los audios presentó dificultades debido a inconsistencias en los puntos de corte entre frases, ruidos ambientales y silencios prolongados. Para resolver esto, se implementaron conjuntos de instrucciones (*scripts*) automáticos basados en WhisperX [38], una herramienta avanzada de reconocimiento automático del habla (*Automatic Speech Recognition*, ASR) [39], que permitió segmentar eficientemente los audios y generar transcripciones precisas.

Asimismo, fue necesario adaptar el conjunto (*set*) de fonemas debido a limitaciones del modelo segmentador (*tokenizador*) empleado, que originalmente estaba diseñado para el idioma inglés. Aunque muchos sonidos son compartidos con el español, ciertos fonemas característicos del acento rioplatense no estaban disponibles, lo que requirió la adaptación y expansión del *set* de *tokens* para representar adecuadamente el habla rioplatense.

3.2.3. Justificación de decisiones

La selección del corpus buscó especialmente garantizar la representatividad y diversidad del español rioplatense, con cobertura de distintas variantes dentro de este dialecto, aunque limitándose específicamente a voces femeninas. Esta restricción fue deliberada dado que el objetivo final del trabajo es generar una voz

sinfética femenina que logre aprender y reproducir con precisión tanto la pronunciación general como el vocabulario moderno y expresiones coloquiales comunes del habla actual.

3.2.4. Consideraciones legales y éticas

Desde el punto de vista ético y legal, se obtuvo el consentimiento verbal explícito de todas las participantes para el uso de las grabaciones realizadas en Discord. El uso autorizado se limitó al ámbito académico y sin fines comerciales. Además, los conjuntos de datos públicos empleados contaron con licencias abiertas adecuadas para investigación académica, lo que garantizó el cumplimiento ético y legal del trabajo.

3.3. Modelo TTS seleccionado

El presente apartado describe el proceso de selección del modelo de conversión de texto a voz que servirá como base para el desarrollo del sistema propuesto. Se exponen las razones técnicas y prácticas que han motivado la elección de SpeechT5, así como su relación con las tendencias actuales en síntesis de voz neuronal. La sección incluye un repaso del paradigma de modelos TTS basados en *Transformers*, una comparación con enfoques anteriores y un análisis detallado de la arquitectura, junto con una valoración de su potencial de adaptación al español rioplatense.

3.3.1. Paradigma de modelos TTS basados en *Transformers*

La síntesis de voz automática ha evolucionado rápidamente gracias al aprendizaje profundo. En lugar de concatenar fragmentos de audio o usar modelos paramétricos tradicionales, los modelos neuronales actuales como Tacotron 2, FastSpeech 2 y Transformer-TTS, generan espectrogramas mel [40] a partir del texto de manera autorregresiva, obteniéndose una calidad de voz muy superior a métodos antiguos. Estos sistemas suelen consistir en un codificador, un mecanismo de atención y un decodificador recurrente que predicen paso a paso el espectrograma, para luego emplear un vocoder neural que obtiene la forma de onda final. Sin embargo, la generación autorregresiva tiende a ser lenta y a veces poco robusta y puede omitir o repetir fragmentos de texto por errores en el alineamiento. Para superar estas limitaciones, se han introducido arquitecturas basadas en *Transformers* que permiten paralelizar la generación y mejorar la estabilidad. Por ejemplo, Transformer-TTS reemplaza las redes recurrentes por auto-atención, lo que acelera el entrenamiento y mantiene calidad comparable a Tacotron 2. Este paradigma facilita la captura de prosodia y entonación complejas gracias a la capacidad de modelar dependencias de largo alcance.

3.3.2. Modelos anteriores: Tacotron 2 y FastSpeech

Dos referentes clásicos de TTS neuronal son Tacotron 2 y FastSpeech. Tacotron 2 introdujo un enfoque de secuencia a secuencia (*sequence-to-sequence*, seq2seq) [41] con un codificador bidireccional de memoria a corto y largo plazo (*bidirectional Long Short-Term Memory*, biLSTM) [42], un mecanismo de atención (*attention*) [43] y un decodificador de memoria a corto y largo plazo (*Long Short-Term Memory*, LSTM) [44] para generar espectrogramas en escala mel directamente a partir del

texto. Aunque produce voces naturales, presenta limitaciones propias de los modelos autoregresivos: el proceso secuencial es lento y susceptible a errores de alineación. FastSpeech adoptó un diseño de transformador de avance directo (*Transformer feed-forward*), que descarta la atención recursiva y utiliza un regulador de duración que expande automáticamente la secuencia de fonemas. Esto permite síntesis mucho más rápida, robusta y evita saltos o repeticiones de palabras. Aunque su calidad es comparable a Tacotron 2 y ofrece control explícito sobre la velocidad y las pausas, su rendimiento ha sido superado por modelos recientes basados en preentrenamiento masivo y arquitecturas más avanzadas.

3.3.3. Arquitectura y funciones del modelo SpeechT5

SpeechT5 es un modelo de codificador-decodificador (*encoder-decoder*) unificado y desarrollado por Microsoft Research [45], que extiende la filosofía del modelo T5 [46] de procesamiento del lenguaje natural (*Natural Language Processing*, PLN) al dominio del habla. Su arquitectura de Transformer central convierte texto en espectrogramas mel o realiza tareas inversas, complementada por redes de preprocesamiento (*pre-nets*) y posprocesamiento (*post-nets*) específicas según la modalidad. Las *pre-nets* acondicionan la entrada: un extractor convolucional procesa audio crudo y para el texto se aplican representaciones vectoriales de palabras (*embeddings*) de *tokens* compartidos. El Transformer procesa estas representaciones y las *post-nets* generan la salida final. Incluye *embeddings* de altavoz para síntesis multivoz y conversión de voz, lo que le otorga gran versatilidad para distintas tareas.

3.3.4. Justificación de la elección de SpeechT5

La elección de SpeechT5 se fundamenta en:

- Flexibilidad multi-tarea: unifica síntesis, traducción hablada, conversión y reconocimiento de voz en una sola arquitectura.
- Calidad y eficiencia: produce voz de alta fidelidad gracias a su preentrenamiento y uso de módulos especializados, con síntesis rápida por su estructura no recurrente.
- Disponibilidad abierta: su código y pesos se publican bajo licencia MIT [47], lo que facilita su adaptación y evita costes de licenciamiento.

3.3.5. Evaluación preliminar para español rioplatense

Aunque SpeechT5 fue entrenado principalmente en inglés y utiliza el corpus de LibriTTS [48], su arquitectura permite la adaptación a nuevos idiomas mediante técnicas de transferencia de aprendizaje (*transfer learning*) como el *fine-tuning* y los adaptadores (*adapters*) [49]. Gracias a esta flexibilidad, con datos de voz representativos del acento rioplatense y sus capacidades multivoz, es posible obtener una síntesis que reproduzca la prosodia y entonación características de esta variante del español. La implementación de un *fine-tuning*, junto con una validación perceptual realizada por hablantes nativos, permite alcanzar resultados de alta calidad.

3.4. Entrenamiento y ajustes

3.5. Integración y validación

3.6. Documentación y reproducibilidad

Capítulo 4

Ensayos y Resultados

4.1. Banco de pruebas

4.1.1. Subsection 1

4.2. Pruebas del modelo TTS

4.3. Pruebas de integración

4.4. Comparación de resultados

4.5. Validación con usuarios

4.6. Caso de uso ejemplar

Capítulo 5

Conclusiones

5.1. Resultados obtenidos

5.2. Trabajo futuro

Bibliografía

- [1] Hanaa Barakat, Ozlem Turk y Cagri Demiroglu. «Deep learning-based expressive speech synthesis: a systematic review of approaches, challenges, and resources». En: *EURASIP Journal on Audio, Speech, and Music Processing* 2024.4 (2024), págs. 1-29. DOI: [10.1186/s13636-024-00329-7](https://doi.org/10.1186/s13636-024-00329-7). URL: <https://asmp-urasipjournals.springeropen.com/articles/10.1186/s13636-024-00329-7>.
- [2] Xu Tan et al. «A Survey on Neural Speech Synthesis». En: *ArXiv abs/2106.15561* (2021). URL: <https://arxiv.org/abs/2106.15561>.
- [3] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [4] Wikipedia contributors. *Fonética y fonología del español rioplatense*. 2024. URL: https://es.wikipedia.org/wiki/Fon%C3%A9tica_y_fonolog%C3%ADa_del_espa%C3%B1ol_rioplatense (visitado 17-07-2025).
- [5] Qian Wan y Zhicong Lu. «Investigating VTubing as a Reconstruction of Streamer Self-Presentation: Identity, Performance, and Gender». En: *ArXiv* (2023). URL: <https://arxiv.org/abs/2307.11025>.
- [6] Wikipedia contributors. *Twitch (service)*. 2025. URL: [https://en.wikipedia.org/wiki/Twitch_\(service\)](https://en.wikipedia.org/wiki/Twitch_(service)) (visitado 17-07-2025).
- [7] Hideki Kenmochi e Hiroshi Ohshita. «VOCALOID—Commercial Singing Synthesizer Based on Sample Concatenation». En: *Proceedings of INTERSPEECH*. 2007, págs. 4011-4010.
- [8] Jonathan Shen et al. «Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions». En: *arXiv preprint arXiv:1712.05884* (2018). URL: <https://arxiv.org/abs/1712.05884>.
- [9] Yi Ren et al. «FastSpeech 2: Fast and High-Quality End-to-End Text to Speech». En: *arXiv preprint arXiv:2006.04558* (2020). URL: <https://arxiv.org/abs/2006.04558>.
- [10] Jungil Kong, Jaehyeon Kim y Jaekyoung Bae. «HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis». En: *arXiv preprint arXiv:2010.05646* (2020). URL: <https://arxiv.org/abs/2010.05646>.
- [11] Ryan Prenger, Rafael Valle y Bryan Catanzaro. «WaveGlow: A Flow-based Generative Network for Speech Synthesis». En: *CoRR* (2018). URL: <http://arxiv.org/abs/1811.00002>.
- [12] Mozilla. *Mozilla TTS: Deep learning for Text to Speech synthesis*. <https://github.com/mozilla/TTS>. 2023. (Visitado 10-07-2025).
- [13] Shinji Watanabe et al. «ESPnet: End-to-End Speech Processing Toolkit». En: *Proceedings of Interspeech*. 2018, págs. 2207-2211.
- [14] Coqui AI. *Coqui TTS: a deep learning toolkit for Text-to-Speech*. <https://github.com/coqui-ai/TTS>. 2023. (Visitado 10-07-2025).
- [15] X (Twitter) contributors. *Vedal (@Vedal987) / X*. 2025. URL: <https://x.com/Vedal987> (visitado 17-07-2025).

- [16] Wikipedia contributors. *Neuro-sama*. 2025. URL: <https://en.wikipedia.org/wiki/Neuro-sama> (visitado 17-07-2025).
- [17] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [18] Naihan Li et al. «Close to Human Quality TTS with Transformer». En: *CoRR* (2018). URL: <http://arxiv.org/abs/1809.08895>.
- [19] ITU-T. *Methods for subjective determination of transmission quality*. Inf. téc. P.800. International Telecommunication Union, 1996.
- [20] Heiga Zen, Keiichi Tokuda y Alan W Black. «Statistical parametric speech synthesis». En: *Speech Communication* (2009).
- [21] Microsoft & IBM. *Waveform Audio File Format*. 1991. URL: <https://docs.fileformat.com/audio/wav/> (visitado 18-07-2025).
- [22] Python Software Foundation. *The Python Tutorial*. 2023. URL: <https://docs.python.org/3/tutorial/> (visitado 18-07-2025).
- [23] Microsoft. *Visual Studio Code*. 2019. URL: <https://code.visualstudio.com/> (visitado 18-07-2025).
- [24] Jupyter Team. *Project Jupyter*. 2015. URL: <https://jupyter.org> (visitado 18-07-2025).
- [25] Adam Paszke et al. «PyTorch: An Imperative Style, High-Performance Deep Learning Library». En: *Advances in Neural Information Processing Systems* 32 (2019).
- [26] Charles R Harris et al. «Array programming with NumPy». En: *Nature* 585.7825 (2020), págs. 357-362.
- [27] Wes McKinney. «Data structures for statistical computing in Python». En: *Proceedings of the 9th Python in Science Conference* 445 (2010), págs. 51-56.
- [28] Brian McFee et al. «librosa: Audio and music signal analysis in Python». En: *Proceedings of the 14th python in science conference*. Vol. 8. 2015, págs. 18-25.
- [29] Google Research. *Google Colaboratory*. 2017. URL: <https://colab.research.google.com> (visitado 18-07-2025).
- [30] María Beatriz Fontanella de Weinberg. *El español hablado en el Río de la Plata: historia, variación y características actuales*. Universidad Nacional de La Plata, 1992.
- [31] Ellen M. Kaisse. «The prosodic structure of Argentinian Spanish». En: *Hispanic Linguistics* 8.2 (1996), págs. 1-24.
- [32] Chengyi Wang et al. *Neural Codec Language Models are Zero-Shot Text to Speech Synthesizers*. 2023. URL: <https://arxiv.org/abs/2301.02111>.
- [33] Kai Shen et al. *NaturalSpeech 2: Latent Diffusion Models are Natural and Zero-Shot Speech and Singing Synthesizers*. 2023. URL: <https://arxiv.org/abs/2304.09116>.
- [34] Matthew Le et al. *Voicebox: Text-Guided Multilingual Universal Speech Generation at Scale*. 2023. URL: <https://arxiv.org/abs/2306.15687>.
- [35] Junyi Ao et al. *SpeechT5: Unified-Modal Encoder-Decoder Pre-Training for Spoken Language Processing*. 2022. URL: <https://arxiv.org/abs/2110.07205>.
- [36] Hugging Face. *Hugging Face: The AI community building the future*. 2025. URL: <https://huggingface.co/> (visitado 02-08-2025).
- [37] Discord Inc. *Discord: Free Voice, Video, and Text Chat for Gamers*. 2025. URL: <https://discord.com/> (visitado 02-08-2025).
- [38] Max Bain et al. *WhisperX: Time-Accurate Speech Transcription of Long-Form Audio*. 2023. URL: <https://arxiv.org/abs/2303.00747>.

- [39] Hamza Kheddar, Mustapha Hemis y Yassine Himeur. «Automatic speech recognition using advanced deep learning approaches: A survey». En: *Information Fusion* 109 (sep. de 2024), pág. 102422. ISSN: 1566-2535. DOI: [10.1016/j.inffus.2024.102422](https://doi.org/10.1016/j.inffus.2024.102422). URL: <http://dx.doi.org/10.1016/j.inffus.2024.102422>.
- [40] Kin Wai Cheuk, Kat Agres y Dorien Herremans. «The impact of Audio input representations on neural network based music transcription». En: *arXiv preprint arXiv:2001.09989* (2020).
- [41] Ilya Sutskever, Oriol Vinyals y Quoc V. Le. «Sequence to Sequence Learning with Neural Networks». En: *arXiv preprint arXiv:1409.3215* (2014).
- [42] Alex Graves y Jürgen Schmidhuber. «Framewise phoneme classification with bidirectional LSTM and other neural network architectures». En: *Neural Networks* 18.5–6 (2005), págs. 602-610.
- [43] Dzmitry Bahdanau, Kyunghyun Cho y Yoshua Bengio. «Neural Machine Translation by Jointly Learning to Align and Translate». En: *arXiv preprint arXiv:1409.0473* (2014).
- [44] Sepp Hochreiter y Jürgen Schmidhuber. «Long Short-Term Memory». En: *Neural Computation* 9.8 (1997), págs. 1735-1780.
- [45] Shuang Yang et al. «SpeechT5: Unified-Modal Encoder-Decoder Pre-training for Spoken Language Processing». En: *arXiv preprint arXiv:2106.07458* (2021).
- [46] Colin Raffel et al. «Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer». En: *Journal of Machine Learning Research* 21.140 (2020), págs. 1-67.
- [47] Open Source Initiative. *MIT License*. <https://opensource.org/licenses/MIT>. (Visitado 02-08-2025).
- [48] Heiga Zen, Keiichi Tokuda y Alan W. Black. «LibriTTS: A Corpus Derived from LibriSpeech for Text-to-Speech». En: *Proceedings of Interspeech 2019*. 2019. URL: <https://arxiv.org/abs/1904.02882>.
- [49] Neil Houlsby et al. «Parameter-Efficient Transfer Learning for NLP». En: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. 2019. URL: <https://arxiv.org/abs/1902.00751>.