


Sesión 3: Explicabilidad, Transparencia y Rendición de Cuentas en Sistemas de IA

Exploraremos el valor ético y social de la explicabilidad, tipos de transparencia, rendición de cuentas y marcos regulatorios clave.



¿Qué es la explicabilidad en IA?

La **explicabilidad** se refiere a la capacidad de un sistema de IA para ofrecer razones comprensibles y justificables sobre sus decisiones. Es fundamental en contextos sensibles como salud o justicia, donde entender el "porqué" de una decisión afecta la confianza y legitimidad del sistema.

A diferencia de la **interpretabilidad**, que implica entendimiento técnico interno, la explicabilidad se enfoca en comunicar a audiencias no técnicas, facilitando transparencia real y accesible.

- **Interpretabilidad:** Cómo funciona el modelo internamente
- **Explicabilidad:** Por qué se tomó una decisión, explicable para cualquier usuario

Fundamentos conceptuales: Transparencia

La transparencia en IA es multidimensional y vital para la confianza:

- **Transparencia algorítmica:** Acceso al código y parámetros que definen el modelo.
- **Transparencia funcional:** Comprender qué hace el sistema y por qué realiza ciertas acciones o decisiones.
- **Transparencia comunicacional:** Cómo se informa de forma clara y accesible al usuario final.

Cada nivel atiende a diferentes audiencias: desarrolladores, reguladores y usuarios.

Fundamentos conceptuales: Rendición de cuentas

La rendición de cuentas define **quién responde** por las decisiones de un sistema de IA, involucrando dimensiones jurídicas, técnicas y éticas.

Se diferencian conceptos clave:

- **Accountability:** Responsabilidad proactiva, ética y operativa antes y durante el uso.
- **Liability:** Responsabilidad legal reactiva, posterior a la ocurrencia de daños.

Una gobernanza robusta integra ambos aspectos para garantizar control y protección efectiva.

Referencias Fundamentales

Estas obras son pilares para profundizar en explicabilidad y ética en IA:

1. Doshi-Velez, F. & Kim, B. (2017). Towards a rigorous science of interpretable ML.
2. Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual explanations without opening the black box.
3. European Commission, AI Act (2024).
4. Jobin, A., Ienca, M., & Vayena, E. (2019). The global landscape of AI ethics guidelines.

Técnicas y herramientas de explicabilidad

El campo de XAI (Explainable Artificial Intelligence) agrupa métodos para hacer comprensibles las predicciones de IA:

- **Métodos post-hoc:** Explicaciones que se derivan tras entrenar el modelo. Ejemplos: LIME, SHAP, mapas de saliencia, explicaciones contrafactuales.
- **Métodos integrados:** Modelos naturalmente explicables como árboles de decisión, modelos lineales parciales y reglas de asociación.

Estos métodos equilibran explicabilidad y precisión, enfrentando retos para mantener ambas cualidades.

XAI: Métodos post-hoc

Estos métodos se aplican tras entrenar modelos complejos (black box) para interpretar decisiones específicas:


LIME (Local Interpretable Model-Agnostic Explanations)

- Genera modelos lineales locales para aproximar y explicar decisiones puntuales.
- Facilita entender *por qué* una predicción fue tomada.

Referencia: Ribeiro et al. (2016)



Shap values contributing to prediction



XAI: Método SHAP

SHAP utiliza teoría de juegos para asignar a cada característica una contribución al resultado del modelo. Permite explicaciones locales y globales.

- Basado en valores de Shapley para equilibrio justo de atribuciones.
- Funciona con modelos variados, facilitando interpretaciones precisas.

Referencia: Lundberg & Lee (2017)

Classification Heatmap



XAI: Mapas de Saliencia en Visión por Computador

En modelos CNN, los mapas de saliencia señalan regiones de una imagen usadas para la predicción, basándose en gradientes que identifican la "atención" del modelo.

Son herramientas visuales útiles para entender qué partes de una imagen influyen la decisión de la IA, especialmente en diagnóstico médico o vigilancia.




XAI: Explicaciones Contrafactuales

Responden a "¿Qué tendría que cambiar para obtener un resultado diferente?" facilitando interpretaciones accionables para usuarios.

Por ejemplo, un sistema bancario puede indicar que un aumento del 10% en ingresos hubiera cambiado la aprobación de un crédito.

Referencia: Wachter et al. (2018)



Métodos Intrínsecos: Modelos Explicables

Algunos modelos son explicables por diseño, sin métodos externos:

- **Árboles de decisión:** Organizados en reglas if-then claras, facilitan trazabilidad y auditoría.
- **Modelos lineales parciales:** Combinan funciones base y regresión para interpretabilidad con capacidad no lineal.
- **Reglas de asociación:** Detectan patrones explícitos tipo “Si A y B entonces C”, útiles en minería de datos y detección de fraude.

Límites de la Explicabilidad

Aunque deseable, la explicabilidad presenta desafíos técnicos y éticos:

- **Trade-off precisión vs. explicabilidad:** Modelos simples explican mejor pero pueden perder precisión frente a modelos complejos.
- **Falsa comprensión:** Explicaciones aproximadas pueden inducir a error si se interpretan literalmente.
- **Omisión contextual:** Explicaciones técnicas suelen ignorar aspectos sociales o legales fundamentales.
- **Desigualdad cognitiva:** No todos los públicos entienden igual; la explicabilidad debe adaptarse al conocimiento del usuario.

Importancia de la Explicabilidad

Explicabilidad es crucial por aspectos éticos, legales y sociales:

- **Ética:** Derecho a comprender decisiones que impactan nuestra vida.
- **Legalidad:** Exigida en regulaciones como AI Act y GDPR, que garantizan derecho a explicación.
- **Confianza:** Aumenta la aceptación pública y uso responsable de la IA.
- **Calidad:** Permite detectar errores, sesgos y auditoría continua.

Transparencia y Rendición de Cuentas en Regulaciones

Examinamos perspectivas globales:

- **Unión Europea (AI Act 2024):** Modelos de alto riesgo requieren documentación técnica, explicaciones accesibles y supervisión humana.
- **General Purpose AI:** Documentación sobre datasets, funcionamiento y riesgos asociados.
- **Latinoamérica:** Leyes como la Ley 1581 en Colombia y fallos constitucionales que exigen trazabilidad y supervisión en IA.

Global AI Regulation



Referencias Clave

1. Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). Why Should I Trust You?
2. Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions.
3. Wachter, S., Mittelstadt, B., & Russell, C. (2018). Counterfactual explanations without opening the black box.
4. Doshi-Velez, F., & Kim, B. (2017). Towards A Rigorous Science of Interpretable Machine Learning.
5. Dastin, J. (2018). Amazon scraps secret AI recruiting tool that showed bias against women.
6. European Union AI Act (2024), Articles 13, 15 and 29.