

Sesión 4: Justicia algorítmica, discriminación y sesgo

Objetivos de aprendizaje

01

Fundamentos del sesgo algorítmico

Comprender qué son el **sesgo algorítmico** y la **discriminación automatizada**, y por qué representan uno de los desafíos éticos más urgentes en el desarrollo de sistemas de IA.

02

Tipos y fases del sesgo

Identificar los diferentes tipos de sesgos que pueden surgir en las distintas fases del ciclo de vida de un sistema de IA, desde el diseño hasta la implementación.

03

Herramientas de medición

Explorar enfoques metodológicos y herramientas técnicas para detectar, medir y mitigar sesgos en algoritmos de aprendizaje automático.

04

Casos de estudio

Analizar casos reales de discriminación algorítmica en sectores críticos como justicia, salud, finanzas, educación y recursos humanos.

05

Marco ético de justicia

Reflexionar sobre la **justicia algorítmica** como marco normativo y ético para el desarrollo responsable de tecnologías de IA.



Fundamentos de sesgo y discriminación algorítmica



Conceptos fundamentales

Sesgo (Bias)


Desviación sistemática de la verdad, la equidad o la representación justa de la realidad. En el contexto algorítmico, se manifiesta como patrones de error que afectan desproporionalmente a ciertos grupos o individuos.

Discriminación algorítmica

Tratamiento desigual, injusto o perjudicial hacia personas o grupos específicos como resultado directo de decisiones automatizadas basadas en algoritmos de inteligencia artificial.

Justicia algorítmica

Conjunto de principios éticos y metodológicos orientados a garantizar que los sistemas de IA respeten la equidad, inclusión y trato justo, independientemente de características protegidas como raza, género o clase social.



Impacto societal: La discriminación algorítmica puede perpetuar y amplificar desigualdades históricas, afectando millones de decisiones diarias en áreas críticas como empleo, crédito, justicia penal y atención médica.

Taxonomía de sesgos algorítmicos

Los sesgos pueden introducirse en múltiples etapas del desarrollo de sistemas de IA. Understanding esta taxonomía es crucial para implementar estrategias efectivas de mitigación.

Tipo de sesgo	Descripción y mecanismo	Ejemplo práctico
Sesgo en los datos	Reflejo de desigualdades históricas, subrepresentación de grupos minoritarios, o datos recopilados de manera no representativa de la población objetivo.	Dataset de investigación médica que incluye predominantemente población masculina, resultando en diagnósticos menos precisos para mujeres.
Sesgo de diseño	Suposiciones implícitas, decisiones arbitrarias del equipo de desarrollo, o elección de métricas de optimización que favorecen ciertos resultados.	Establecimiento de umbrales de clasificación sin justificación empírica que sistemáticamente excluye candidatos de ciertos grupos demográficos.
Sesgo de uso	Errores de interpretación, aplicación incorrecta del modelo en contextos no previstos, o falta de adaptación cultural y contextual.	Implementación de sistema de IA médica desarrollado en un país en poblaciones con características genéticas y culturales diferentes.

Referencia académica: Barocas, S., Hardt, M., & Narayanan, A. (2019). *Fairness and Machine Learning: Limitations and Opportunities*. Una obra seminal que establece los fundamentos teóricos para entender la justicia algorítmica.



Detección y medición de sesgos

Métricas fundamentales de equidad

Demographic Parity

Paridad demográfica: Garantiza que la tasa de resultados positivos sea idéntica para todos los grupos demográficos. Fórmula: $P(\hat{Y} = 1 | A = 0) = P(\hat{Y} = 1 | A = 1)$


Equalized Odds

Oportunidades equalizadas: Las tasas de verdaderos positivos y falsos positivos deben ser iguales entre grupos. Considera tanto la sensibilidad como la especificidad del modelo.

Predictive Parity

Paridad predictiva: La precisión predictiva (valor predictivo positivo) debe ser equivalente across todos los grupos demográficos protegidos.

⚠ **Tensión matemática:** Estas métricas pueden ser mutuamente incompatibles. Optimizar una puede deteriorar otra, requiriendo decisiones éticas explícitas sobre qué tipo de equidad priorizar.





Herramientas tecnológicas para auditoría



IBM AI Fairness 360

Conjunto integral de métricas y algoritmos para detectar y mitigar sesgos. Incluye más de 70 métricas de equidad y 10 algoritmos de mitigación. Soporta diferentes tipos de datos y casos de uso.



Google What-If Tool

Herramienta interactiva de visualización que permite explorar modelos de ML sin código. Facilita el análisis de equidad y la comprensión del comportamiento del modelo.

La implementación de estas herramientas debe ser parte integral del proceso de desarrollo, no una consideración posterior. Las auditorías regulares permiten identificar sesgos emergentes y ajustar los modelos antes de causar daño real.



Microsoft Fairlearn

Toolkit de Python que permite evaluar y mejorar la equidad de modelos de machine learning. Especialmente útil para implementar constraints de equidad durante el entrenamiento.



Audit-AI

Librería open-source especializada en auditorías de sesgo. Proporciona métricas estadísticas robustas y genera reportes detallados sobre potenciales discriminaciones.





Caso de estudio: COMPAS y la justicia penal



El algoritmo que juzgó con prejuicios

El sistema COMPAS (Correctional Offender Management Profiling for Alternative Sanctions) representa uno de los casos más documentados y controvertidos de sesgo algorítmico en el sistema de justicia penal estadounidense.

01

Implementación masiva

Utilizado en múltiples estados para evaluar el riesgo de reincidencia criminal, influyendo en decisiones de libertad condicional, sentencias y programas de rehabilitación.

02

Investigación reveladora

La investigación de *ProPublica* en 2016 analizó más de 7,000 casos en el condado de Broward, Florida, revelando patrones sistemáticos de discriminación racial.

03

Sesgo cuantificado

Los defendants afroamericanos tenían casi el doble de probabilidad de ser incorrectamente clasificados como de alto riesgo comparados con defendants blancos.

04

Impacto sistémico

Perpetuó y amplificó desigualdades históricas en el sistema de justicia, afectando miles de vidas y familias de manera desproporcionada.

"Los algoritmos pueden ser tan sesgados como los humanos que los crean y los datos históricos que los alimentan. COMPAS no fue una excepción: reprodujo los prejuicios raciales del sistema de justicia penal estadounidense."

Discriminación en recursos humanos: El caso Amazon

Cuando la IA perpetúa la desigualdad laboral

En 2018, Reuters reveló que Amazon había desarrollado un sistema de inteligencia artificial para automatizar el reclutamiento que sistemáticamente discriminaba contra candidatas mujeres, especialmente en roles técnicos.

Cronología del sesgo

2014-2017: Desarrollo

Amazon entrenó el algoritmo utilizando CVs enviados a la empresa durante una década, período en que la industria tech estaba dominada por hombres.

1

2

2017: Detección

Los ingenieros descubrieron que el sistema penalizaba CVs que contenían la palabra "women's" (como en "women's chess club captain") y favorecía candidatos de universidades predominantemente masculinas.

3

2018: Abandono

Amazon decidió dismantlar el proyecto después de múltiples intentos fallidos de corregir el sesgo de género del sistema.

Lección clave

Los datos históricos sesgados producen algoritmos sesgados. Sin intervención activa, la IA perpetúa y amplifica las desigualdades existentes.

Impacto sectorial

Este caso alertó a toda la industria sobre los riesgos de automatizar procesos de RR.HH. sin consideraciones de equidad.




Sesgo racial en algoritmos de salud

El costo humano del sesgo médico

Un estudio publicado en *Science* en 2019 reveló cómo un algoritmo ampliamente utilizado en el sistema de salud estadounidense discriminaba sistemáticamente contra pacientes afroamericanos, negándoles acceso equitativo a programas de atención médica especializada.

Mecanismo de discriminación

- **Proxy problemático:** El algoritmo utilizaba el costo histórico de atención médica como indicador de necesidad de salud
- **Sesgo sistémico:** Los pacientes afroamericanos históricamente reciben menos atención médica debido a barreras socioeconómicas
- **Círculo vicioso:** Menor gasto histórico se tradujo en menor prioridad algorítmica, perpetuando la desigualdad



43.2M

Pacientes afectados

Número estimado de personas impactadas por este algoritmo sesgado en el sistema de salud estadounidense

17.7%

Reducción necesaria

Disminución requerida en el sesgo para lograr paridad racial en las derivaciones médicas

⊗ **Advertencia ética:** En el sector salud, los sesgos algorítmicos no solo perpetúan desigualdades sociales, sino que pueden tener consecuencias directas sobre la vida y muerte de los pacientes.

Crisis educativa: Algoritmos y desigualdad académica

El algoritmo que amplificó la desigualdad educativa

Durante la pandemia de COVID-19, cuando los exámenes presenciales fueron cancelados, el Reino Unido implementó un algoritmo de calificación automática que generó una de las controversias educativas más grandes de la década.


El sistema Ofqual (2020)

- 1

Criterio problemático
El algoritmo asignaba calificaciones basándose principalmente en el rendimiento histórico del colegio, no en el mérito individual del estudiante.
- 2


Discriminación sistemática
Los estudiantes de colegios públicos y de bajos ingresos recibieron calificaciones significativamente más bajas que sus contrapartes de colegios privados.
- 3

Revuelta social
Las protestas masivas y la presión pública obligaron al gobierno a revertir completamente el sistema en apenas dos semanas.



Calificaciones reducidas

Porcentaje de estudiantes que vieron sus calificaciones disminuidas por el algoritmo



Estudiantes afectados

Número aproximado de jóvenes cuyas oportunidades universitarias fueron comprometidas

Reflexión final: Este caso ilustra cómo los algoritmos pueden perpetuar y amplificar las desigualdades socioeconómicas existentes, especialmente cuando se implementan sin considerar adecuadamente sus implicaciones éticas y sociales.

La justicia algorítmica no es solo un desafío técnico, sino un **imperativo moral** que requiere vigilancia constante, transparencia radical y compromiso con la equidad en cada etapa del desarrollo tecnológico.